

概率论部分总结

黄体棠

2026 春

目录

1	概率论知识网络架构	2
2	知识清单	3
2.1	基本概念定义	3
2.1.1	事件与概率	3
2.1.2	随机变量与分布	3
2.1.3	条件信息与独立性	4
2.1.4	数字特征	5
2.2	常用分布汇总表	6
2.2.1	离散型分布	6
2.2.2	连续型分布	6
2.3	重要定理与结论	7
2.3.1	基本定理与公式	7
2.3.2	数字特征的性质	7
2.3.3	独立性与不相关性	8
2.3.4	随机变量函数的分布	8
2.3.5	极限定理	9
2.3.6	重要结论补充	10
3	常见分析思路	12
3.1	条件概率、全概率与 Bayes 公式	12
3.2	多维随机变量及其函数的分布	13
3.3	条件期望的运用	14
3.4	示性函数与截尾	17
3.5	极限定理的应用	17

1 概率论知识网络架构

概率论部分主要研究随机现象并揭示蕴藏在其中的结构和规律。整个知识体系的推进逻辑如下：

- **从事件到概率：**首先从随机试验和随机事件出发，建立样本空间的概念。随后，通过古典概型和几何概型引入概率的直观计算，并最终走向 Kolmogorov 的概率公理化定义，奠定严格的数学基础。
- **从事件到随机变量：**为了更方便地进行数学处理，引入“随机变量”将样本空间映射到实数轴上。根据取值特征，分别深入研究离散型和连续型随机变量的分布律和概率密度函数。
- **从一维到多维：**将单个随机变量推广到随机向量，研究多个变量之间的联合分布、边缘分布以及条件分布，并引入随机变量的独立性概念。
- **从分布到特征：**分布函数虽然完整，但过于繁琐。因此引入数学期望、方差、协方差和矩等数字特征，从平均水平、散布程度和相关性等维度高度概括随机变量的本质特征。
- **从微观到宏观 (极限定理)：**最后，通过大数定律 (LLN) 和中心极限定理 (CLT)，揭示大量随机变量叠加后呈现的宏观确定性（如依概率收敛于均值，以及近似服从正态分布），这也是数理统计的基石。

章节	核心内容	逻辑关系
1. 事件与概率	样本空间、事件运算、概率公理、古典/几何概型	基础概念与计算工具
2. 条件概率与独立性	条件概率、乘法公式、全概率、Bayes 公式、独立性	刻画信息更新与事件关联
3. 随机变量及其分布	离散/连续型随机变量、分布律/密度、常见分布族	从事件到变量的抽象
4. 多维随机变量	联合分布、边缘分布、条件分布、独立性、函数分布	变量间关系的量化
5. 数字特征	期望、方差、协方差、相关系数、矩	分布特征的数值概括
6. 极限定理	大数定律、中心极限定理	大样本下的统计规律

学习提示：

- 牢记常用分布的定义、期望和方差。
- 理解条件概率与全概率公式，它们是连接不同事件信息的桥梁。
- 掌握随机变量函数的分布求法（分布函数法、卷积公式、变量变换法）。
- 注意独立与不相关的区别，仅在正态场合等价。
- 极限定理是数理统计的基石，要理解依概率收敛与依分布收敛的含义。

2 知识清单

2.1 基本概念定义

2.1.1 事件与概率

定义 1 (随机试验). 随机现象的实现和对它某个特征的观测

定义 2 (基本事件). 随机试验中的每个单一结果

定义 3 (样本空间). 随机试验中所有基本事件所构成的集合, 通常用 Ω 表示

定义 4 (样本点). 样本空间中的元素, 通常用 ω 表示

定义 5 (事件的关系及运算). 随机试验的样本空间足够大, 我们就可以把使得事件 A 发生的全部试验结果集合 A' 和事件 A 建立一一对应, 事件的关系及运算也就对应集合之间的关系及运算

定义 6 (古典概型下概率定义). 样本点有限且等可能时, 事件 A 发生的概率 $P(A) = \frac{|A|}{|\Omega|}$

定义 7 (公理化概率定义).

设 Ω 为样本空间, $\mathcal{F}$ 为事件域. 概率 P 是 $\mathcal{F} \rightarrow [0, 1]$ 的映射, 满足:

1. 非负性: $\forall A \in \mathcal{F}, P(A) \geq 0$;
2. 规范性: $P(\Omega) = 1$;
3. 可列可加性: 若 $A_i \in \mathcal{F}$ 两两互斥, 则 $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$.

2.1.2 随机变量与分布

定义 8 (随机变量). 设 Ω 为样本空间, $X: \Omega \rightarrow \mathbb{R}$ 为实值函数. 若对任意实数 $x, \{\omega: X(\omega) \leq x\} \in \mathcal{F}$, 则称 X 为随机变量。

定义 9 (分布函数).

随机变量 X 的 (累积) 分布函数 (cdf) 定义为 $F(x) = P(X \leq x)$, $x \in \mathbb{R}$ 。

则可以用分布函数表示概率: $P(a < X \leq b) = F(b) - F(a)$

定义 10 (离散型随机变量).

若 X 只取有限个或可数个值, 则称 X 为离散型随机变量。

其分布律或概率质量函数 (pmf) 为 $p_i = P(X = x_i)$, 满足 $p_i \geq 0$ 且 $\sum_i p_i = 1$ 。

注意分布律 $\neq$ 分布函数

定义 11 (连续型随机变量).

若存在非负可积函数 $f(x)$, 使得 $F(x) = \int_{-\infty}^x f(t) dt$, 则称 X 为连续型随机变量。

$f(x)$ 为概率密度函数 (pdf), 满足 $\int_{-\infty}^{\infty} f(x) dx = 1$ 。

定义 12 (多维随机变量).

设

$$X = (X_1, X_2, \dots, X_n),$$

如果每个 $X_i (i = 1, 2, \dots, n)$ 都是一个随机变量, 则称 X 为 n 维随机变量或随机向量

定义 13 (离散型随机向量).

若 $X = (X_1, \dots, X_n)$ 中每个分量都是离散型随机变量, 则称 X 为离散型随机向量
 设 X_i 的可能取值为

$$\{a_{i1}, a_{i2}, \dots\}, \quad i = 1, 2, \dots, n,$$

则称

$$p(j_1, \dots, j_n) = P(X_1 = a_{1j_1}, \dots, X_n = a_{nj_n})$$

为随机向量 X 的联合概率质量函数或联合分布律, 其中 $j_1, \dots, j_n = 1, 2, \dots$

定义 14 (连续型随机向量).

若存在 $\mathbb{R}^n$ 上的非负函数 $f(x_1, \dots, x_n)$, 使

$$P(a_i \leq X_i \leq b_i, i = 1, \dots, n) = \int_{a_1}^{b_1} \cdots \int_{a_n}^{b_n} f(x_1, \dots, x_n) dx_1 \cdots dx_n$$

其中 $-\infty < a_i \leq b_i < +\infty, i = 1, \dots, n$, 则称 $X = (X_1, \dots, X_n)$ 为 n 维连续型随机向量, f 为联合概率密度函数

或者是用分布函数的一个等价定义:

若存在 $\mathbb{R}^n$ 上的非负函数 $f(x_1, \dots, x_n)$, 使

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \cdots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_1 \cdots dt_n$$

则称 $X = (X_1, \dots, X_n)$ 为 n 维连续型随机向量, f 为联合概率密度函数

这里 F 称为联合分布函数: $F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$

定义 15 (边缘分布).

目标变量的边缘概率质量 (密度) 函数是联合概率质量 (密度) 函数对其余变量求和 (积分)

2.1.3 条件信息与独立性

定义 16 (事件的条件概率).

设 $P(B) > 0$, 在 B 发生下 A 的条件概率为 $P(A|B) = \frac{P(AB)}{P(B)}$.

定义 17 (事件的独立性).

若事件 A, B 满足 $P(AB) = P(A)P(B)$, 则称 A 与 B 相互独立

若 $P(B) > 0$, 则 A, B 独立的充要条件为: $P(A|B) = P(A)$

定义 18 (事件列的独立性).

设 $A_1, \dots, A_n$ 是随即试验中的 n 个事件, 用 $\tilde{A}_i$ 表示 A_i 或 $\bar{A}_i$ 之一, 若满足:

$$P(\tilde{A}_1 \cdots \tilde{A}_n) = P(\tilde{A}_1) \cdots P(\tilde{A}_n) \quad (1)$$

则称事件列 $A_1, \dots, A_n$ 相互独立 (上面共有 2^n 个等式)

相互独立的一个等价表述:

对 $A_1, \dots, A_n$ 中的任意 k 个事件 $A_{i_1}, \dots, A_{i_k}, k = 2, \dots, n$, 有:

$$P(A_{i_1}, \dots, A_{i_k}) = P(A_{i_1}) \cdots P(A_{i_k}) \quad (2)$$

若事件 $A_1, \dots, A_n$ 中任意两个事件都相互独立, 则称它们两两独立

相互独立一定两两独立；两两独立不一定相互独立

定义 19 (随机变量 (向量) 的条件分布).

设 $(X_1, X_2, \dots, X_n) \sim f(x_1, x_2, \dots, x_n)$, 且 $(X_1, \dots, X_k) \sim g(x_1, \dots, x_k)$, 则可定义在 $(X_1, \dots, X_k) = (x_1, \dots, x_k)$ 的条件下, $(X_{k+1}, \dots, X_n)$ 的条件密度为:

$$h(x_{k+1}, \dots, x_n | x_1, \dots, x_k) = \frac{f(x_1, \dots, x_n)}{g(x_1, \dots, x_k)}, \quad \text{其中 } g(x_1, \dots, x_k) > 0.$$

注: 若记 $(X_1, \dots, X_k) = \mathbf{X}$, $(X_{k+1}, \dots, X_n) = \mathbf{Y}$, $(x_1, \dots, x_k) = \mathbf{x}$, $(x_{k+1}, \dots, x_n) = \mathbf{y}$, 则上式还可表示为:

$$h(\mathbf{y} | \mathbf{x}) = \frac{f(\mathbf{x}, \mathbf{y})}{g(\mathbf{x})}, \quad g(\mathbf{x}) > 0$$

即:

$$\boxed{\text{条件分布} = \text{联合分布} \div \text{条件变量边缘分布}}$$

定义 20 (随机变量的独立性).

若对任意区域 A, B ,

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

则称 X, Y 相互独立

推广到 n 维:

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod P(X_i \in A_i)$$

其中 A_i 为任一实数区间, 则称随机变量 $X_1, \dots, X_n$ 相互独立

2.1.4 数字特征

定义 21 (数学期望).

离散型: $E(X) = \sum_i x_i P(X = x_i)$; 连续型: $E(X) = \int_{-\infty}^{\infty} x f(x) dx$ (要求绝对收敛)。

定义 22 (条件期望).

设 X, Y 为随机变量。若 (X, Y) 为离散型, 且在给定 $X = x$ 下, Y 有分布 $P(Y = a_i | X = x) = p_i$; 或者 (X, Y) 为连续型, 且在给定 $X = x$ 下, Y 的条件密度为 $f(y|x)$ 。则

$$E(Y|X=x) = \begin{cases} \sum_i a_i p_i, & \text{离散型,} \\ \int_{-\infty}^{\infty} y f(y|x) dy, & \text{连续型.} \end{cases}$$

定义 23 (方差).

$$\text{Var}(X) = E[(X - EX)^2] = E(X^2) - (EX)^2.$$

定义 24 (矩).

设 X 为随机变量, c 为常数, r 为正整数, 则 $E[(X - c)^r]$ 称为 X 关于 c 点的 r 阶矩。

1. $c = 0$ 。这时 $\alpha_r = EX^r$ 称为 X 的 r 阶原点矩。

2. $c = EX$ 。这时 $\mu_r = E[(X - EX)^r]$ 称为 X 的 r 阶中心矩。

定义 25 (协方差与相关系数).

$$\text{Cov}(X, Y) = E[(X - EX)(Y - EY)] = E(XY) - EX \cdot EY \quad \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$$

当 $\rho_{X,Y} = 0$ 时, 称 X 与 Y 不相关。

2.2 常用分布汇总表

2.2.1 离散型分布

分布名称	参数	分布律 $P(X = k)$	期望 EX	方差 $Var(X)$
0-1 分布	$p \in (0, 1)$	$p^k(1-p)^{1-k}$ $k = 0, 1$	p	$p(1-p)$
二项分布 $B(n, p)$	$n \geq 1, p \in (0, 1)$	$\binom{n}{k}p^k(1-p)^{n-k}$ $0 \leq k \leq n$	np	$np(1-p)$
几何分布 $G(p)$	$p \in (0, 1)$	$(1-p)^{k-1}p$ $k = 1, 2, \dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Pascal 分布	$r \geq 1, p \in (0, 1)$	$\binom{k-1}{r-1}p^r(1-p)^{k-r}$ $k = r, r+1, \dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
Poisson 分布 $P(\lambda)$	$\lambda > 0$	$e^{-\lambda} \frac{\lambda^k}{k!}$ $k = 0, 1, \dots$	λ	λ
超几何分布	N, M, n	$\frac{\binom{M}{k}\binom{N-M}{n-k}}{\binom{N}{n}}$	$n \frac{M}{N}$	$n \frac{M}{N} (1 - \frac{M}{N}) \frac{N-n}{N-1}$

2.2.2 连续型分布

分布名称	参数	密度函数 $f(x)$	期望	方差
均匀分布 $U(a, b)$	$a < b$	$\frac{1}{b-a}$ $a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布 $Exp(\lambda)$	$\lambda > 0$	$\lambda e^{-\lambda x}$ $x > 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布 $N(\mu, \sigma^2)$	$\mu \in \mathbb{R}, \sigma > 0$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
Gamma 分布 $\Gamma(\alpha, \beta)$	$\alpha, \beta > 0$	$\frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}$ $x > 0$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
卡方分布 $\chi^2(n)$	$n \in \mathbb{N}^+$	$\frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}$ $x > 0$	n	$2n$
t 分布 $t(n)$	$n \in \mathbb{N}^+$	$\frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi}\Gamma(\frac{n}{2})} (1 + \frac{x^2}{n})^{-\frac{n+1}{2}}$	0 $(n > 1)$	$\frac{n}{n-2}$ $(n > 2)$
F 分布 $F(m, n)$	$m, n \in \mathbb{N}^+$	$\frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{m}{2})\Gamma(\frac{n}{2})} (\frac{m}{n})^{\frac{m}{2}} x^{\frac{m}{2}-1} (1 + \frac{m}{n}x)^{-\frac{m+n}{2}}$ $x > 0$	$\frac{n}{n-2}$ $(n > 2)$	$\frac{2n^2(m+n-2)}{m(n-2)^2(n-4)}$ $(n > 4)$

2.3 重要定理与结论

2.3.1 基本定理与公式

定理 1 (全概率公式).

设 $\{B_i\}$ 为 Ω 的一个分割 (互不相交且并集为全空间), 且 $P(B_i) > 0$, 则

$$P(A) = \sum_i P(A|B_i)P(B_i).$$

定理 2 (Bayes 公式).

条件同上, 且 $P(A) > 0$, 则

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}.$$

定理 3 (乘法公式).

$$P(A_1 A_2 \cdots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \cdots P(A_n|A_1 \cdots A_{n-1}).$$

2.3.2 数字特征的性质

性质 1 (期望的性质).

1. 线性: $E(aX + bY) = aEX + bEY$ (无条件)
2. 独立可乘: 若 X, Y 独立, 则 $E(XY) = EX \cdot EY$
3. 全期望公式: $E(X) = E[E(X|Y)]$

性质 2 (方差的性质).

1. $Var(cX) = c^2 Var(X)$, $Var(X + c) = Var(X)$
2. 若 X, Y 独立, 则 $Var(X \pm Y) = Var(X) + Var(Y)$
3. 一般地, $Var(X \pm Y) = Var(X) + Var(Y) \pm 2Cov(X, Y)$

性质 3 (协方差的性质).

1. $Cov(X, Y) = Cov(Y, X)$, $Cov(X, X) = Var(X)$
2. $Cov(aX, bY) = ab Cov(X, Y)$
3. $Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$
4. 若 X, Y 独立, 则 $Cov(X, Y) = 0$ (反之不真)
5. Cauchy-Schwarz 不等式: $|E(XY)| \leq \sqrt{E(X^2)E(Y^2)}$.

则 $|Cov(X, Y)| \leq \sqrt{Var(X)Var(Y)}$, 即 $|\rho_{XY}| \leq 1$ 。等号成立当且仅当 X, Y 存在线性关系。

2.3.3 独立性与不相关性

定理 4 (独立性的等价条件).

离散型:

称离散型随机变量 $X_1, \dots, X_n$ 相互独立, 若它们的联合分布律等于各自的边缘分布律的乘积即

$$P(X_1 = x_1, \dots, X_n = x_n) = P(X_1 = x_1) \cdots P(X_n = x_n),$$

其中 $(x_1, \dots, x_n)$ 为 $(X_1, X_2, \dots, X_n)$ 的值域中的任意一点。

连续型:

称连续型随机变量 $X_1, \dots, X_n$ 相互独立, 若它们的联合密度等于各自的边缘密度的乘积即

$$f(x_1, \dots, x_n) = f_1(x_1) \cdots f_n(x_n), \quad \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

分布函数:

一般的, 随机变量之间的独立性可以通过分布函数来刻画:

设 $X_1, \dots, X_n$ 为 n 个随机变量, 如果它们的联合分布函数等于各自边缘分布函数的乘积即

$$F(x_1, \dots, x_n) = F_1(x_1) \cdots F_n(x_n), \quad \forall (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$$

则称随机变量 $X_1, \dots, X_n$ 相互独立

性质 4.

- 独立 $\Rightarrow$ 不相关; 但不相关 $\nRightarrow$ 独立。
- 对于二元正态分布, 独立 $\Leftrightarrow$ 不相关 ($\rho = 0$)。

2.3.4 随机变量函数的分布

定理 5 (卷积公式).

若 X, Y 独立, 密度分别为 f_X, f_Y , 则 $Z = X + Y$ 的密度为

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx.$$

定理 6 (商的分布).

若 X, Y 独立, 密度分别为 f_X, f_Y , 且 $Y \neq 0$, 则 $Z = X/Y$ 的密度为

$$f_Z(z) = \int_{-\infty}^{\infty} |y| f_X(zy) f_Y(y) dy.$$

定理 7 (密度变换公式).

一维情形:

设随机变量 ξ 的密度函数为 $p_\xi(x)$, 定义域为 $a < x < b$ 。如果可以把 (a, b) 分割为一些 (有限个或可列个) 互不重叠的子区间的和 $(a, b) = \bigcup_j I_j$, 使得函数 $u = g(t)$ 在每个子区间 I_j 上严格单调, 且反函数为 $t = h_j(u)$, 那么 $\eta = g(\xi)$ 的密度函数为:

$$p_\eta(u) = \sum_j p_\xi(h_j(u)) \cdot |h'_j(u)|.$$

特别的, 若 $u = g(t)$ 在 (a, b) 上严格单调, 则其反函数 $t = h(u)$ 存在且唯一, $\eta = g(\xi)$ 的密度函数为: $p_\eta(u) = p_\xi(h(u)) \cdot |h'(u)|$

多维情形:

如果 $(\xi_1, \dots, \xi_n)$ 是 n 维连续型随机向量, 具有联合密度函数

$$p(x_1, \dots, x_n)$$

假设存在 n 个 n 元函数

$$y_j = f_j(x_1, \dots, x_n), \quad j = 1, \dots, n,$$

使得

$$\zeta_j = f_j(\xi_1, \dots, \xi_n), \quad j = 1, \dots, n.$$

若 $(\xi_1, \dots, \xi_n)$ 与 $(\zeta_1, \dots, \zeta_n)$ 之间一一对应, 逆映射为

$$\xi_j = h_j(\zeta_1, \dots, \zeta_n), \quad j = 1, \dots, n,$$

其中每个 $h_j(y_1, \dots, y_n)$ 都有一阶连续偏导数, 那么随机向量 $(\zeta_1, \dots, \zeta_n)$ 是连续型的, 且具有联合密度函数

$$q(y_1, \dots, y_n) = \begin{cases} p(h_1(y_1, \dots, y_n), \dots, h_n(y_1, \dots, y_n)) |J|, & (y_1, \dots, y_n) \in D, \\ 0, & (y_1, \dots, y_n) \notin D, \end{cases}$$

其中 D 是随机向量 $(\zeta_1, \dots, \zeta_n)$ 的所有可能值的集合, J 是变换的 *Jacobi* 行列式, 即

$$J = \begin{vmatrix} \frac{\partial h_1}{\partial y_1} & \dots & \frac{\partial h_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial h_n}{\partial y_1} & \dots & \frac{\partial h_n}{\partial y_n} \end{vmatrix}.$$

2.3.5 极限定理

定理 8 ((弱) 大数定律 LLN).

设 $\{X_n\}$ 独立同分布, $E(X_1) = \mu$, 则样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 依概率收敛到 μ , 即 $\bar{X}_n \xrightarrow{P} \mu$.

定理 9 ((Lindeberg-Lévy) 中心极限定理 CLT).

设 $\{X_n\}$ 独立同分布, $E(X_1) = \mu$, $Var(X_1) = \sigma^2 < \infty$, 则

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n}\sigma} \xrightarrow{d} N(0, 1).$$

即标准化和依分布收敛于标准正态分布。

定理 10 (De Moivre-Laplace 定理).

若 $S_n \sim B(n, p)$, 则当 n 充分大时,

$$\frac{S_n - np}{\sqrt{np(1-p)}} \xrightarrow{d} N(0, 1).$$

实际计算中常采用连续性校正: $P(a \leq S_n \leq b) \approx \Phi\left(\frac{b+0.5-np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a-0.5-np}{\sqrt{np(1-p)}}\right)$.

2.3.6 重要结论补充

性质 5 (无记忆性).

对随机变量 X , 满足 $P(X > s + t | X > s) = P(X > t)$

- 离散型: 几何分布是唯一具有无记忆性的离散分布。
- 连续型: 指数分布是唯一具有无记忆性的连续分布。

性质 6 (再生性).

相互独立的两个同类型随机变量之和仍服从同一类型的分布

- 二项分布: 若 $X \sim B(n, p)$, $Y \sim B(m, p)$, 且 X 和 Y 相互独立。则 $X + Y \sim B(n + m, p)$ 。
- 泊松分布: 若 $X \sim P(\lambda)$, $Y \sim P(\mu)$, 且 X 和 Y 独立。则 $X + Y \sim P(\lambda + \mu)$ 。
- 卡方分布: 若 $X \sim \chi_m^2$, $Y \sim \chi_n^2$ 且相互独立, 则 $X + Y \sim \chi_{m+n}^2$ 。
- 正态分布: 若 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, 且 X 与 Y 相互独立, 则

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

更一般地, 若 $X_1, \dots, X_n$ 相互独立, $X_i \sim N(\mu_i, \sigma_i^2)$, $a_1, \dots, a_n, b$ 为任意 $n + 1$ 个实数 ($a_1, \dots, a_n$ 不全为零), 令

$$X = \sum_{i=1}^n a_i X_i + b,$$

则

$$X \sim N(\mu, \sigma^2),$$

其中

$$\mu = \sum_{i=1}^n a_i \mu_i + b, \quad \sigma^2 = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

- 伽马分布: 设 X 和 Y 独立, 均服从伽马分布 $\Gamma(1, \lambda)$, 则 $X + Y \sim \Gamma(2, \lambda)$

性质 7 (正态分布的性质).

- 若 $X_i \sim N(\mu_i, \sigma_i^2)$, 则 $a_i X_i + b_i \sim N(a_i \mu_i + b_i, a_i^2 \sigma_i^2)$
- 若 $X_i \sim N(0, 1)$ 独立, 则 $\sum_{i=1}^n X_i^2 \sim \chi^2(n)$ 。
- 若 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 独立, 则 $\frac{X}{\sqrt{Y/n}} \sim t(n)$ 。
- 若 $X \sim \chi^2(m)$, $Y \sim \chi^2(n)$ 独立, 则 $\frac{X/m}{Y/n} \sim F(m, n)$ 。

性质 8 (矩母函数与特征函数).

随机变量 X 的矩母函数定义为 $M_X(t) = E(e^{tX})$ 。特征函数定义为 $\phi_X(t) = E(e^{itX})$ 。

- 矩母函数在 0 点附近存在时, $M_X^{(k)}(0) = E(X^k)$ 。
- 特征函数总是存在, 且唯一决定分布 (唯一性定理)。
- 独立随机变量和的矩母函数 (特征函数) 等于各自矩母函数 (特征函数) 的乘积。

性质 9 (常见不等式).

- *Markov* 不等式: $X \geq 0, a > 0 \Rightarrow P(X \geq a) \leq \frac{E(X)}{a}$.
- *Chebyshev* 不等式: $P(|X - EX| \geq \epsilon) \leq \frac{Var(X)}{\epsilon^2}$.

3 常见分析思路

3.1 条件概率、全概率与 Bayes 公式

特征：已知部分结果，反推原因的概率；或利用中间状态分割复杂事件。

思路：遇到多阶段试验或信息更新问题时，核心在于构建“分割”（互斥且完备的事件组）。利用全概率公式求解“总结果”的概率，利用 Bayes 公式求解“执果索因”的后验概率。对于复杂的路径问题（如随机游走），可运用“一步条件化”（首步分析法）构建递推方程。

例 1 (Bayes 公式).

设有甲和乙两个罐子，甲罐中有 m 个红球和 n 个黑球，乙罐中有 n 个红球和 m 个黑球，且 $m > n$ 。某人随机选取一个罐子并从中随机抽取一球，发现为红球，现将该球放回原罐后并摇匀。然后再次在此罐中随机抽取一球，则它仍为红色的概率是否比 $1/2$ 大？通过计算事件的概率来证明你的结论。

解.

设事件 A 表示选取的罐子为甲罐，事件 A^c 表示选取乙罐。设事件 R_1 表示第一次取出红球，事件 R_2 表示第二次取出红球。已知 $P(A) = P(A^c) = 1/2$ 。

由全概率公式和条件概率可知：

$$P(R_1|A) = \frac{m}{m+n}, \quad P(R_1|A^c) = \frac{n}{m+n}$$

由 Bayes 公式求第一次取出红球后，罐子是甲罐的后验概率：

$$P(A|R_1) = \frac{P(R_1|A)P(A)}{P(R_1|A)P(A) + P(R_1|A^c)P(A^c)} = \frac{\frac{m}{m+n} \cdot \frac{1}{2}}{\frac{m}{m+n} \cdot \frac{1}{2} + \frac{n}{m+n} \cdot \frac{1}{2}} = \frac{m}{m+n}$$

同理 $P(A^c|R_1) = \frac{n}{m+n}$ 。

在已知第一次为红球的条件下，第二次取球时罐子已经确定（带有对应的后验概率）。由全概率公式：

$$\begin{aligned} P(R_2|R_1) &= P(R_2|A)P(A|R_1) + P(R_2|A^c)P(A^c|R_1) \\ &= \frac{m}{m+n} \cdot \frac{m}{m+n} + \frac{n}{m+n} \cdot \frac{n}{m+n} = \frac{m^2 + n^2}{(m+n)^2} \end{aligned}$$

由于 $m > n > 0$ ，有 $(m-n)^2 > 0 \Rightarrow m^2 + n^2 > 2mn \Rightarrow 2(m^2 + n^2) > (m+n)^2$ 。

故 $P(R_2|R_1) = \frac{m^2 + n^2}{(m+n)^2} > \frac{1}{2}$ 。结论成立。 $\square$

例 2 (全概率与递推).

甲乙两坛子中各装一只白球和一只黑球，从两坛中各取出一球交换后放入另一坛中。记事件 A_n, B_n, C_n 分别表示第 n 次交换后甲坛的白球数是 2, 1, 0。记 p_n, q_n, r_n 为其概率，求关系式并讨论 $n \rightarrow \infty$ 的情形。

解.

利用全概率公式建立递推关系：

$$p_{n+1} = P(A_{n+1}|B_n)P(B_n) = \frac{1}{4}q_n$$

$$q_{n+1} = P(B_{n+1}|A_n)P(A_n) + P(B_{n+1}|B_n)P(B_n) + P(B_{n+1}|C_n)P(C_n) = p_n + \frac{1}{2}q_n + r_n$$

利用 $p_n = r_n$ 及 $p_n + q_n + r_n = 1$ ，消去 p_n, r_n 得 $q_{n+1} - q_n = -\frac{1}{2}(q_n - q_{n-1})$ 。结合初值得 $q_n = \frac{2}{3} \left[1 - \left(-\frac{1}{2}\right)^{n+1} \right]$ ， $p_n = r_n = \frac{1}{6} \left[1 - \left(-\frac{1}{2}\right)^n \right]$ 。当 $n \rightarrow \infty$ 时， $p_\infty = r_\infty = \frac{1}{6}$ ， $q_\infty = \frac{2}{3}$ 。 $\square$

例 3 (随机游走).

平面上有 n 个不同的点, 编号分别为 $1, 2, \dots, n$. 现有一个质点在这些点上做随机游动, 假设每次它在某点上停留片刻之后就会在其余所有点中等概率选择一个并移动到该点上. 设其初始位置为点 1 上, 则它在第一次返回此点之前访问过点 2 的概率是多少?

解.

记事件 C_1 为“从点 1 出发, 在第一次返回点 1 之前访问过点 2”.

第一步移动有 $n-1$ 种等可能的选择:

- 若第一步直接移动到点 2 (概率 $\frac{1}{n-1}$), 则目标事件必然发生.
- 若第一步移动到除 1 和 2 之外的其余 $n-2$ 个点中的任意一点 k (概率 $\frac{n-2}{n-1}$).

设事件 A_k 表示“从点 k 出发, 在第一次到达点 1 之前访问过点 2”. 由全概率公式 (即一步条件化):

$$P(C_1) = \frac{1}{n-1} \cdot 1 + \frac{n-2}{n-1} P(A_k)$$

由图的对称性可知, 对于任意 $k \notin \{1, 2\}$, 点 k 到点 1 和点 2 的地位是完全等价的. 即质点从点 k 出发, 先到达点 1 和先到达点 2 的概率必定相等.

因此 $P(A_k) = \frac{1}{2}$.

代入上式得:

$$P(C_1) = \frac{1}{n-1} + \frac{n-2}{n-1} \cdot \frac{1}{2} = \frac{2+n-2}{2(n-1)} = \frac{n}{2(n-1)}$$

□

3.2 多维随机变量及其函数的分布

思路: 针对连续型随机向量的变换, 首选 **雅可比行列式变换**. 需明确为一一对应关系, 计算反函数的行列式, 并严格确定新变量的取值范围, 若反函数不方便计算, 也可求原函数的行列式, 再求倒数即可. 对于随机变量的商、和、最值分布, 可灵活结合定义与常用公式, 也可根据随机向量变换后求边缘分布.

例 4 (随机截断与商的分布).

将区间 $(0, 2)$ 随机截成两段, 记较短一段的长度为 X , 较长一段的长度为 Y .

(1) 求 X 的概率密度函数 $f(x)$;

(2) 求 $Z = Y/X$ 的概率密度函数 $g(z)$;

(3) 设随机变量 X^* 与 X 独立同分布, 试求 $V = 2|X - X^*|$ 的概率密度函数 $h(v)$.

解.

(1) 设截断点为 $U \sim U(0, 2)$. 则两段长度为 U 和 $2-U$. 由于 X 为较短长度, 有 $X = \min\{U, 2-U\}$.

显然 X 的取值范围是 $(0, 1)$. 对 $0 < x < 1$:

$$F_X(x) = P(X \leq x) = P(U \leq x \text{ 或 } U \geq 2-x) = P(U \leq x) + P(U \geq 2-x) = \frac{x}{2} + \frac{x}{2} = x$$

故 $X \sim U(0, 1)$, 概率密度 $f_X(x) = 1, 0 < x < 1$.

(2) 由题意 $X + Y = 2$, 故 $Z = \frac{Y}{X} = \frac{2-X}{X} = \frac{2}{X} - 1$.

反解得 $X = \frac{2}{Z+1}$. 因为 $0 < X < 1$, 可得 $Z > 1$.

单调变换求导: $|x'(z)| = \left| -\frac{2}{(z+1)^2} \right| = \frac{2}{(z+1)^2}$ 。

根据密度变换公式 $g(z) = f_X(x(z))|x'(z)|$:

$$g(z) = 1 \cdot \frac{2}{(z+1)^2} = \frac{2}{(z+1)^2}, \quad z > 1$$

(3) X, X^* 独立同分布于 $U(0, 1)$, 则联合分布在单位正方形 $(0, 1) \times (0, 1)$ 内均匀分布。

要求 $V = 2|X - X^*|$ 的分布。由于 $0 < X, X^* < 1$, 故 $0 \leq V \leq 2$ 。

对 $0 \leq v \leq 2$, $P(V \leq v) = P(|X - X^*| \leq v/2)$ 。在单位正方形内, 该事件对应区域为夹在直线 $X - X^* = v/2$ 与 $X^* - X = v/2$ 之间的面积。

阴影部分面积 = 正方形总面积 - 两个直角边为 $(1 - v/2)$ 的等腰直角三角形面积:

$$H(v) = 1 - 2 \times \frac{1}{2} \left(1 - \frac{v}{2}\right)^2 = 1 - \left(1 - \frac{v}{2}\right)^2 = v - \frac{v^2}{4}$$

求导得概率密度:

$$h(v) = H'(v) = 1 - \frac{v}{2}, \quad 0 \leq v \leq 2$$

□

例 5 (三维连续型变量的联合变换)。

设随机向量 (X, Y, Z) 的概率密度函数为 $f(x, y, z) = 8xyz$, $0 < x, y, z < 1$ 。设随机变量 $U = X$, $V = XY$, $W = XYZ$ 。求 (U, V, W) 的联合概率密度函数 $g(u, v, w)$, 并判断是否独立。

解。

构建多维变换: $u = x$, $v = xy$, $w = xyz$ 。

反解出原变量:

$$x = u, \quad y = \frac{v}{u}, \quad z = \frac{w}{v}$$

求雅可比行列式:

$$J = \frac{\partial(x, y, z)}{\partial(u, v, w)} = \begin{vmatrix} 1 & 0 & 0 \\ -\frac{v}{u^2} & \frac{1}{u} & 0 \\ 0 & -\frac{w}{v^2} & \frac{1}{v} \end{vmatrix} = \frac{1}{u} \cdot \frac{1}{v} = \frac{1}{uv}$$

确定定义域: 因为 $0 < x, y, z < 1$, 代入反解式得到 $0 < u < 1$, $0 < \frac{v}{u} < 1$, $0 < \frac{w}{v} < 1$ 。化简得定义域为:

$$0 < w < v < u < 1$$

由多维密度变换公式:

$$g(u, v, w) = f(x(u, v, w), y(u, v, w), z(u, v, w))|J| = 8(u) \left(\frac{v}{u}\right) \left(\frac{w}{v}\right) \cdot \frac{1}{uv} = \frac{8w}{uv}, \quad 0 < w < v < u < 1$$

判断独立性: 虽然 $g(u, v, w)$ 的表达式主体可以分离变量, 但其定义域 $0 < w < v < u < 1$ 不是矩形区域 (且边界互相依赖), 因此 U, V, W 不相互独立。□

3.3 条件期望的运用

思路: 条件密度 $f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)}$ 的计算十分程式化, 但积分限容易出错。务必画出联合分布的支撑集 (可行域)。条件期望 $E(Y|X = x)$ 实际上是对条件密度积分; 并且可以结合**全期望公式** $E(Y) = E[E(Y|X)]$ 或 **重期望公式** $E(XY) = E[X \cdot E(Y|X)]$ 快速计算复杂期望和协方差。

我们先介绍一个有用的公式

定理 11 (全方差公式 / 方差分解公式).

设 X 与 Y 为随机变量, 且 $Var(Y) < \infty$, 则

$$Var(Y) = E[Var(Y | X)] + Var(E[Y | X]).$$

其中, $Var(Y | X) = E[(Y - E[Y | X])^2 | X]$ 为条件方差。

证明.

由方差定义 $Var(Y) = E[Y^2] - (E[Y])^2$, 我们对右端两项分别处理。

首先, 由全期望公式 (即期望的 tower property):

$$E[Y] = E[E[Y | X]].$$

其次, 利用条件期望的平滑性计算 $E[Y^2]$:

$$E[Y^2] = E[E[Y^2 | X]].$$

根据条件方差的定义,

$$Var(Y | X) = E[Y^2 | X] - (E[Y | X])^2,$$

因此

$$E[Y^2 | X] = Var(Y | X) + (E[Y | X])^2.$$

两边取期望得

$$E[Y^2] = E[Var(Y | X)] + E[(E[Y | X])^2].$$

将 $E[Y^2]$ 和 $E[Y]$ 的表达式代入方差的定义:

$$\begin{aligned} Var(Y) &= E[Y^2] - (E[Y])^2 \\ &= \left(E[Var(Y | X)] + E[(E[Y | X])^2] \right) - (E[E[Y | X]])^2. \end{aligned}$$

注意到 $E[(E[Y | X])^2] - (E[E[Y | X]])^2$ 恰好是随机变量 $E[Y | X]$ 的方差, 即

$$Var(E[Y | X]) = E[(E[Y | X])^2] - (E[E[Y | X]])^2.$$

代入即得

$$Var(Y) = E[Var(Y | X)] + Var(E[Y | X]).$$

□

例 6 (联合密度、条件期望与相关系数).

设二维随机向量 (X, Y) 的联合概率密度函数为 $f(x, y) = cx(y - x)e^{-y}$, $0 \leq x \leq y < \infty$ 。

(1) 求常数 c ;

(2) 求条件概率密度函数 $f_{Y|X}(y|x)$;

(3) 求期望 $E[XY]$ 以及 X, Y 的相关系数 $Corr(X, Y)$ 。

解.

(1) 利用联合密度的归一性求 c . 注意积分限 (推荐先对 x 积分):

$$\int_0^\infty dy \int_0^y cx(y - x)e^{-y} dx = 1$$

内层积分: $\int_0^y (xy - x^2)dx = \frac{1}{2}x^2y - \frac{1}{3}x^3 \Big|_0^y = \frac{y^3}{6}$ 。

外层积分: $c \int_0^\infty \frac{y^3}{6} e^{-y} dy = \frac{c}{6} \Gamma(4) = \frac{c}{6} \times 3! = c$ 。故 $c = 1$ 。

(2) 先求 X 的边缘密度:

$$f_X(x) = \int_x^\infty x(y-x)e^{-y} dy = xe^{-x} \int_x^\infty (y-x)e^{-(y-x)} dy = xe^{-x} \int_0^\infty te^{-t} dt = xe^{-x}, \quad x > 0$$

(可见 $X \sim \Gamma(2, 1)$)。

条件密度函数为:

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} = \frac{x(y-x)e^{-y}}{xe^{-x}} = (y-x)e^{-(y-x)}, \quad y \geq x > 0$$

(3) 注意到上述条件密度 $f_{Y|X}(y|x)$ 结构表明: 在 $X = x$ 条件下, $Y - x \sim \Gamma(2, 1)$ 。

因此 $E[Y - x|X = x] = 2 \Rightarrow E[Y|X = x] = x + 2$ 。所以条件期望 $E[Y|X] = X + 2$ 。

利用全期望公式求 $E(Y)$ 和 $E(XY)$:

$$EX = 2, \quad \text{Var}(X) = 2 \Rightarrow E(X^2) = 6$$

$$EY = E[E(Y|X)] = E(X + 2) = EX + 2 = 4$$

$$E[XY] = E[X \cdot E(Y|X)] = E[X(X + 2)] = E(X^2) + 2EX = 6 + 4 = 10$$

为了求相关系数, 还要求 $E(Y^2)$ 。已知 $Y - X|X \sim \Gamma(2, 1)$, 其方差为 2, 故 $\text{Var}(Y|X) = 2$ 。

由全方差公式:

$$\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E(Y|X)) = E[2] + \text{Var}(X + 2) = 2 + \text{Var}(X) = 2 + 2 = 4$$

$$\text{Cov}(X, Y) = E(XY) - EXEY = 10 - 2 \times 4 = 2$$

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}} = \frac{2}{\sqrt{2 \times 4}} = \frac{\sqrt{2}}{2}$$

□

例 7 (复合随机变量与极值分布)。

设 $X, Y, U_1, U_2, \dots$ 相互独立, 且 X, Y 分布律为 $P(X = n) = (e-1)e^{-n}$, $P(Y = n) = \frac{1}{(e-1)n!}$ 。 $U_i \sim U(0, 1)$ 。记 $M = \max\{U_1, U_2, \dots, U_Y\}$, 求 M 的概率密度函数 $f_M(x)$ 。

解。

题目中 Y 作为一个随机的个数, 需要使用全概率公式 (条件化)。

已知当 $Y = n$ 给定时, M 是 n 个独立同分布于 $U(0, 1)$ 的随机变量的最大值。其条件分布函数为:

$$P(M \leq x|Y = n) = P(\max_{1 \leq i \leq n} U_i \leq x) = P(U_1 \leq x, \dots, U_n \leq x) = x^n, \quad 0 \leq x \leq 1$$

利用全概率公式求 M 的边缘分布函数:

$$P(M \leq x) = \sum_{n=1}^{\infty} P(M \leq x|Y = n)P(Y = n) = \sum_{n=1}^{\infty} x^n \frac{1}{(e-1)n!} = \frac{1}{e-1} \sum_{n=1}^{\infty} \frac{x^n}{n!}$$

注意到泰勒展开 $e^x - 1 = \sum_{n=1}^{\infty} \frac{x^n}{n!}$, 故:

$$F_M(x) = P(M \leq x) = \frac{e^x - 1}{e - 1}, \quad 0 \leq x \leq 1$$

对 x 求导得到概率密度函数:

$$f_M(x) = F'_M(x) = \frac{e^x}{e - 1}, \quad 0 \leq x \leq 1$$

(在区间外 $f_M(x) = 0$)。

□

3.4 示性函数与截尾

思路：计算离散复杂事件的期望时，“将随机变量分解为若干个示性函数之和”是一项极其核心的技巧。即 $X = \sum_{i=1}^n I_i$ 。再利用期望的线性性质 $E(X) = \sum_{i=1}^n E(I_i) = \sum_{i=1}^n P(A_i)$ 。在收敛性证明或界的估计中，可以利用示性函数进行截尾处理： $X = X(I_{|X| \leq M} + I_{|X| > M})$ ，再进行分析以及使用常见不等式等

例 8 (示性函数的电梯模型).

一座楼共 n 层，有一个载有 m 人的升降电梯在这 n 层楼里停靠若干次，每个人随机独立选择一层楼停靠。求电梯平均停靠的总次数。

解.

记 T 为电梯停靠的总次数。直接求 T 的分布非常困难，但可以将其分解。

定义示性变量 I_i ($i = 1, 2, \dots, n$)，表示第 i 层楼是否有人停靠：

$$I_i = \begin{cases} 1, & \text{第 } i \text{ 层有人下车} \\ 0, & \text{第 } i \text{ 层无人下车} \end{cases}$$

显然总停靠次数 $T = I_1 + I_2 + \dots + I_n$ 。

由于每个人独立地以概率 $\frac{1}{n}$ 选择第 i 层，因此一个人不选择第 i 层的概率是 $1 - \frac{1}{n}$ 。

m 个人都不选择第 i 层的概率为 $(1 - \frac{1}{n})^m$ 。因此：

$$E(I_i) = P(I_i = 1) = 1 - P(\text{无人选择第 } i \text{ 层}) = 1 - \left(1 - \frac{1}{n}\right)^m$$

利用期望的线性性，无论各层停靠是否独立，均有：

$$E(T) = E\left(\sum_{i=1}^n I_i\right) = \sum_{i=1}^n E(I_i) = n \left[1 - \left(1 - \frac{1}{n}\right)^m\right]$$

□

3.5 极限定理的应用

思路：大数定律：样本均值 $\xrightarrow{P}$ 总体均值；中心极限定理：当 n 较大时，独立同分布和的标准化形式近似服从 $N(0, 1)$ 。用于近似计算概率。对于离散分布，常用连续性校正；**依概率收敛与依分布收敛的关系：**依概率收敛可推出依分布收敛；若收敛到常数，则两者等价；**Slutsky 引理：**在研究统计量的渐进性质中经常用到。常表现为：方差未知时，由于样本方差 $S_n^2 \xrightarrow{P} \sigma^2$ ，故可以用 S_n 替换 CLT 分母中的 σ 而依然保持渐近标准正态分布。

定理 12 (Slutsky 引理).

若 $X_n \xrightarrow{d} X, Y_n \xrightarrow{P} b, Z_n \xrightarrow{P} c$ ，则 $X_n Y_n + Z_n \xrightarrow{d} bX + c$

注：若 $b \neq 0$ ，则 $Y_n^{-1} \xrightarrow{P} b^{-1}$

例 9 (CLT 与连续性校正).

抛一枚均匀硬币 400 次，求正面次数在 190 到 210 之间的概率近似值。

解.

设 $S \sim B(400, 0.5)$, $ES = 200, Var(S) = 100$ 。由 CLT 并用连续性校正:

$$\begin{aligned} P(190 \leq S \leq 210) &= P(189.5 < S < 210.5) \\ &\approx \Phi\left(\frac{210.5 - 200}{10}\right) - \Phi\left(\frac{189.5 - 200}{10}\right) \\ &= \Phi(1.05) - \Phi(-1.05) \\ &\approx 0.7062 \end{aligned}$$

□

例 10 (大数定律).

设 $X_1, \dots, X_n$ 是来自参数 $\lambda = 3$ 的指数分布总体的简单随机样本, 若 $\frac{1}{n} \sum X_i^2 \xrightarrow{P} a$, 求 a 。

解.

由大数定律, $\frac{1}{n} \sum X_i^2 \xrightarrow{P} E(X_1^2)$ 。对于 $Exp(3)$, $E(X_1) = 1/3, Var(X_1) = 1/9$ 。

故 $E(X_1^2) = Var(X_1) + (EX_1)^2 = 1/9 + 1/9 = 2/9$ 。所以 $a = 2/9$ 。

□

例 11 (包含方差估计的渐近分布证明)。

设均值为 μ , 方差为 σ^2 的随机变量列 $\{X_n\}$ 独立同分布, 且四阶矩有限。令 $\bar{X} = \frac{1}{n} \sum_{k=1}^n X_k$ 。

证明:

$$\frac{\sum_{k=1}^n (X_k - \mu)}{\sqrt{\sum_{k=1}^n (X_k - \bar{X})^2}} \xrightarrow{D} N(0, 1)$$

解.

首先重写分母:

$$\sum_{k=1}^n (X_k - \bar{X})^2 = \sum_{k=1}^n (X_k - \mu + \mu - \bar{X})^2 = \sum_{k=1}^n (X_k - \mu)^2 - n(\bar{X} - \mu)^2$$

将其除以 $n\sigma^2$:

$$\frac{\sum_{k=1}^n (X_k - \bar{X})^2}{n\sigma^2} = \frac{1}{n\sigma^2} \sum_{k=1}^n (X_k - \mu)^2 - \frac{(\bar{X} - \mu)^2}{\sigma^2}$$

由大数定律, $\frac{1}{n} \sum_{k=1}^n (X_k - \mu)^2 \xrightarrow{P} E[(X_1 - \mu)^2] = \sigma^2$ 。故第一项依概率收敛于 1。

由大数定律, $\bar{X} \xrightarrow{P} \mu$ 。故第二项依概率收敛于 0。

综上:

$$V_n^2 := \frac{\sum_{k=1}^n (X_k - \bar{X})^2}{n\sigma^2} \xrightarrow{P} 1 \implies V_n \xrightarrow{P} 1$$

另一方面, 由中心极限定理 (Lindeberg-Lévy CLT):

$$Z_n := \frac{\sum_{k=1}^n (X_k - \mu)}{\sqrt{n}\sigma} \xrightarrow{D} N(0, 1)$$

根据 Slutsky 定理, 若 $Z_n \xrightarrow{D} Z$ 且 $V_n \xrightarrow{P} c$ (c 为常数非零), 则 $\frac{Z_n}{V_n} \xrightarrow{D} \frac{Z}{c}$ 。

这里取 $c = 1$, $Z \sim N(0, 1)$, 则:

$$\frac{Z_n}{V_n} = \frac{\frac{\sum_{k=1}^n (X_k - \mu)}{\sqrt{n}\sigma}}{\frac{\sum_{k=1}^n (X_k - \bar{X})^2}{\sqrt{n}\sigma}} = \frac{\sum_{k=1}^n (X_k - \mu)}{\sqrt{\sum_{k=1}^n (X_k - \bar{X})^2}} \xrightarrow{D} N(0, 1)$$

□