

统计部分习题课讲义

欧泽民

2026年6月3日

1 概率部分复习

中心极限定理

依概率收敛 (定义4.13)

随机变量序列 $\{\xi_n\}$ 依概率收敛于 ξ , 记为 $\xi_n \xrightarrow{P} \xi$, 如果:

$$\forall \varepsilon > 0, \quad \lim_{n \rightarrow \infty} P(|\xi_n - \xi| \geq \varepsilon) = 0$$

依分布收敛 (定义4.14)

设 $X_1, X_2, \dots, X_n, \dots$ 为一列实值随机变量, X 为随机变量, F_n 和 F 分别为随机变量 X_n 和 X 的分布函数, 如果对 F 的所有连续点¹ $x \in \mathbb{R}$ 有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

那么称 $\{F_n\}$ 弱收敛 (converge weakly) 于 F , 也称 $\{X_n\}$ 依分布收敛 (converge in distribution) 于 X , 常记为 $X_n \xrightarrow{L} X$

大数定律 (定理4.4)

设 $\{X_n\}$ 独立同分布, $E(X_1) = \mu$, 则:

$$\bar{X}_n = \frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu \quad (n \rightarrow \infty)$$

Markov 不等式 (定理4.1)

1. 对任意非负随机变量 X 和 $a > 0$:

$$P(X \geq a) \leq \frac{E(X)}{a}$$

2. 若 X 非负且 $k > 0$, 则对任意 $a > 0$:

$$P(X \geq a) \leq \frac{E(X^k)}{a^k}$$

¹这里注意这个条件是不可或缺的, 反例见C4P157E36

Chebyshev 不等式 (定理4.1)

1. 对任意随机变量 X 和 $\varepsilon > 0$:

$$P(|X - E(X)| \geq \varepsilon) \leq \frac{\text{Var}(X)}{\varepsilon^2}$$

2. 对任意 $\varepsilon > 0$:

$$P(|Y| \geq \varepsilon) \leq \frac{E(Y^2)}{\varepsilon^2}$$

例 1.1. (22秋季第六题) 设随机变量 X 服从参数为 3 的 *Poisson* 分布, Y 服从正态分布 $N(3, 1)$, 且它们相互独立, 则由切比雪夫不等式可得概率 $P(X - 3 < Y < X + 3)$ 满足 ()

$$(A) \leq \frac{1}{4} \quad (B) \leq \frac{4}{9} \quad (C) \geq \frac{3}{4} \quad (D) \geq \frac{5}{9}$$

解答

设 $X \sim \text{Poisson}(3)$, $Y \sim N(3, 1)$, 且 X 与 Y 相互独立。事件 $\{X - 3 < Y < X + 3\}$ 等价于 $\{|Y - X| < 3\}$

令 $Z = Y - X$, 则:

$$\text{Var}(Z) = \text{Var}(Y) + \text{Var}(X) = 1 + 3 = 4$$

由切比雪夫不等式: 对任意 $k > 0$,

$$P(|Z - E(Z)| \geq \varepsilon) \leq \frac{\text{Var}(Z)}{\varepsilon^2}$$

于是

$$P(|Z| \geq 3) \leq \frac{4}{9}$$

因此,

$$P(|Z| < 3) \geq 1 - \frac{4}{9} = \frac{5}{9}$$

故正确的选项是 D

中心极限定理 (CLT) (定理4.6)

设 $\{X_n\}$ 独立同分布², $E(X_1) = \mu$, $\text{Var}(X_1) = \sigma^2$, 则标准化和:

$$Z_n = \frac{1}{\sqrt{n}\sigma} \left(\sum_{k=1}^n X_k - n\mu \right)$$

依分布收敛于标准正态分布 $N(0, 1)$, 即:

$$Z_n \xrightarrow{d} N(0, 1) \quad (n \rightarrow \infty)$$

或等价地:

$$\lim_{n \rightarrow \infty} F_{Z_n}(x) = \Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

其中 $\Phi(x)$ 是标准正态分布函数

²实际上条件可以放宽到满足Lindeberg条件, 实际上必要条件是方差有限

叶茨连续性校正 (Yates' Continuity Correction)

老师上课时提到用连续分布（正态）近似离散分布（二项、泊松）时，直接计算累积概率会低估，因忽略了整数点间的半个单位。尤其在小样本或边界概率时误差明显，但是我们可以将离散整数 k 视作区间 $[k - 0.5, k + 0.5)$ 的中点，从而：

$$P(X \leq k) \approx \Phi\left(\frac{k + 0.5 - np}{\sqrt{np(1-p)}}\right), \quad P(X \geq k) \approx 1 - \Phi\left(\frac{k - 0.5 - np}{\sqrt{np(1-p)}}\right)$$

例 1.2. 一个复杂的系统由 100 个相互独立起作用的部件所组成。在整个运行期间每个部件损坏的概率为 0.10。为了使整个系统起作用，至少必须有 85 个部件正常工作，求整个系统起作用的概率

解. 系统由 100 个独立部件组成，每个部件损坏概率 0.1，即正常工作的概率 0.9，设 X 为正常工作的部件数，则 $X \sim B(100, 0.9)$

$$P(X \geq 85) = 1 - P(X \leq 84) \approx 1 - \Phi\left(\frac{84.5 - 90}{\sqrt{100 \times 0.9 \times 0.1}}\right) = \Phi(1.8333) \approx 0.9664$$

□

1.1 统计量的三大分布

χ^2 分布（卡方分布）

定义1: χ^2 分布 (Chi-squared distribution)

设样本 $(X_1, X_2, \dots, X_n)$ 为来自标准正态总体的一个独立随机样本，定义

$$X = X_1^2 + X_2^2 + \dots + X_n^2$$

则 X 服从自由度为 n 的 χ^2 分布，记为 $X \sim \chi_n^2$

通过数学归纳法及独立随机变量和的概率密度函数公式，可以求得 χ_n^2 分布的概率密度函数为：

$$f_n(x) = \frac{1}{\Gamma(n/2)2^{n/2}} e^{-x/2} x^{(n-2)/2} I_{(0,\infty)}(x)$$

其中 $\Gamma(\cdot)$ 为伽马函数， $I_{(0,\infty)}(x)$ 为区间 $(0, \infty)$ 上的指示函数

性质1: χ^2 分布的概率密度函数的支撑集为 $(0, \infty)$ ，从图可见，当自由度 $n = 1, 2$ 时，曲线单调下降趋于 0；而当 $n \geq 3$ 时，曲线呈单峰形状，从 0 开始先单调上升，达到峰值后再单调下降趋于 0




图 1: chi-squared distribution

分位数：查表

性质2: χ^2 分布还具有以下性质：均值与方差：

$$E(X) = n \quad \text{Var}(X) = 2n$$

Student-t 分布

t 分布是英国统计学家戈塞特在 1907 年以 Student 笔名首次发表的：定义2: 若 $Y \sim \chi_n^2$ ，且 $X \sim N(0, 1)$ ，且 X, Y 相互独立，则

$$T = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布，记为 $T \sim t_n$

用独立随机变量商的概率密度函数公式可以求得 t_n 分布的概率密度函数为

$$f_n(t) = \frac{\Gamma((n+1)/2)}{\sqrt{n\pi}\Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad t \in \mathbb{R}$$

性质 t 分布具有下列性质：

性质1: 当 $n = 1$ 时， t 分布就是柯西分布，此时概率密度函数为柯西分布（其实两个标准正态分布商的分布就是cauchy分布）：

$$f_1(t) = \frac{1}{\pi(1+t^2)}, \quad t \in \mathbb{R}$$

性质2: 若 $T \sim t_n$ ，则当 $n \geq 2$ 时，由对称性可得 $E(T) = 0$ ；当 $n \geq 3$ 时， $\text{Var}(T) = \frac{n}{n-2}$

性质3: 当 $n \rightarrow \infty$ 时， t_n 分布的概率密度函数趋于标准正态分布概率密度函数，

$$\lim_{n \rightarrow \infty} f_n(t) = \varphi(t)$$




图 2: Student-t Distribution

上图给出了 t_n 分布的密度函数形状。 t_n 的概率密度函数曲线与标准正态分布 $N(0, 1)$ 的概率密度函数曲线很相似，它们都关于原点对称，单峰偶函数，在 $t = 0$ 处达到极大。但 t_n 的峰值低于标准正态分布的峰值， t_n 的两侧尾部要比标准正态分布的两侧尾部粗一些（也就是重尾分布）

性质4: 若 $T \sim t_n$ ，记 $P(T > c) = \alpha$ ，则 $c = t_n(\alpha)$ 称为自由度为 n 的 t 分布的上 α 分位点。当 α 和 n 给定时， $t_n(\alpha)$ 可查表求出，例如 $t_{12}(0.05) = 1.7823$ ， $t_9(0.025) = 2.262$ 等

F分布

F分布在方差分析中有重要应用。它用于比较两个独立样本的方差比值。具体而言，统计量由两个独立的卡方分布变量的比值构成。

定义3:

$$F_{m,n} = \frac{X_1^2/m}{X_2^2/n}$$

其中， $X_1 \sim \chi_m^2$ 和 $X_2 \sim \chi_n^2$ ，且 X_1 和 X_2 相互独立。F分布的概率密度函数

$$f_{m,n}(x) = \frac{m^{m/2} n^{n/2} \Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} x^{\frac{m}{2}-1} (mx+n)^{-\frac{m+n}{2}} \cdot I_{(0,\infty)}(x)$$

其中， $I_{(0,\infty)}(x)$ 是示性函数，仅当 $x > 0$ 时该值为 1，其他情况为 0

性质1: 若 $Z \sim F_{m,n}$ ，则 $\frac{1}{Z} \sim F_{n,m}$

性质2: 若 $T \sim t_n$ ，则 $T^2 \sim F_{1,n}$

性质3: $F_{m,n}(1-\alpha) = \frac{1}{F_{n,m}(\alpha)}$

性质4: F分布的上分位数给定 $F \sim F_{m,n}$ ，若 $P(F > c) = \alpha$ ，则 $c = F_{m,n}(\alpha)$ 称为 F 分布的上 α 分位数。通过查表可以得到对应的上分位数。




图 3: F distribution

Gamma 分布

设随机变量 X 服从形状参数 $\alpha > 0$ 、率参数 $\beta > 0$ 的 Gamma 分布，其概率密度函数为

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \quad x > 0$$

记为 $X \sim \text{Gamma}(\alpha, \beta)$

1. 指数分布——Gamma 分布的特例

令 $\alpha = 1$ ，则 Gamma 分布退化为指数分布：

$$\text{Gamma}(1, \beta) \equiv \text{Exp}(\beta)$$

此时密度为 $f(x) = \beta e^{-\beta x}$ ，表示“无记忆”的等待时间

2. 卡方分布—— $\beta = 1/2$ 的 Gamma

若令 $\alpha = \nu/2$ (ν 为自由度)， $\beta = 1/2$ ，则 Gamma 分布即为中心卡方分布：

$$\chi^2(\nu) \equiv \text{Gamma}\left(\frac{\nu}{2}, \frac{1}{2}\right)$$

卡方分布是正态随机变量平方和的分布

3. 正态分布与 t 分布——通过卡方 (Gamma) 构造

- 若 $Z \sim N(0, 1)$ ，则 $Z^2 \sim \chi^2(1) = \text{Gamma}(1/2, 1/2)$ 。
- 设 $V \sim \chi^2(\nu) = \text{Gamma}(\nu/2, 1/2)$ 且与 Z 独立，则

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t(\nu)$$

因此， t 分布由正态变量与 Gamma 变量（卡方）复合而成

4. F 分布——两个独立 Gamma 变量之比

设 $U \sim \chi^2(\nu_1) = \text{Gamma}(\nu_1/2, 1/2)$ ， $V \sim \chi^2(\nu_2) = \text{Gamma}(\nu_2/2, 1/2)$ 且独立，则

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F(\nu_1, \nu_2)$$

F 分布完全由两个具有相同率参数 $\beta = 1/2$ 的 Gamma 变量通过比率构造

2 正态总体检验

2.1 各种情形下的检验方法

这里展示了正态总体下一样本和两样本的均值方差检验。

	参数	H_0	H_1	检验统计量及其分布	拒绝域
一样本	σ^2 已知	$\mu = \mu_0$	$\mu \neq \mu_0$	$U = \frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma}$ $U \mu = \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
		$\mu \leq \mu_0$	$\mu > \mu_0$		$U > u_{\alpha}$
		$\mu \geq \mu_0$	$\mu < \mu_0$		$U < -u_{\alpha}$
	σ^2 未知	$\mu = \mu_0$	$\mu \neq \mu_0$	$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}$ $T \mu = \mu_0 \sim t_{n-1}$	$ T > t_{n-1}(\alpha/2)$
		$\mu \leq \mu_0$	$\mu > \mu_0$		$T > t_{n-1}(\alpha)$
		$\mu \geq \mu_0$	$\mu < \mu_0$		$T < -t_{n-1}(\alpha)$
	μ 已知	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi_{\mu}^2 = \frac{nS_{\mu}^2}{\sigma_0^2}$ $\chi_{\mu}^2 \sigma_0^2 \sim \chi_n^2$	$\frac{nS_{\mu}^2}{\sigma_0^2} < \chi_n^2(1 - \alpha/2)$ 或 $\frac{nS_{\mu}^2}{\sigma_0^2} > \chi_n^2(\alpha/2)$
		$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$\frac{nS_{\mu}^2}{\sigma_0^2} > \chi_n^2(\alpha)$
		$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$\frac{nS_{\mu}^2}{\sigma_0^2} < \chi_n^2(1 - \alpha)$
	μ 未知	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$ $\chi^2 \sigma_0^2 \sim \chi_{n-1}^2$	$\frac{(n-1)S^2}{\sigma_0^2} < \chi_{n-1}^2(1 - \alpha/2)$ 或 $\frac{(n-1)S^2}{\sigma_0^2} > \chi_{n-1}^2(\alpha/2)$
		$\sigma^2 \leq \sigma_0^2$	$\sigma^2 > \sigma_0^2$		$\frac{(n-1)S^2}{\sigma_0^2} > \chi_{n-1}^2(\alpha)$
		$\sigma^2 \geq \sigma_0^2$	$\sigma^2 < \sigma_0^2$		$\frac{(n-1)S^2}{\sigma_0^2} < \chi_{n-1}^2(1 - \alpha)$
两样本	σ_1^2, σ_2^2 已知	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$U = \frac{\bar{Y} - \bar{X} - \mu_0}{\sqrt{\frac{\sigma_1^2}{m} + \frac{\sigma_2^2}{n}}}$ $U \mu_0 \sim N(0, 1)$	$ U > u_{\alpha/2}$
		$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$U > u_{\alpha}$
		$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$U < -u_{\alpha}$
	σ_1^2, σ_2^2 未知	$\mu_2 - \mu_1 = \mu_0$	$\mu_2 - \mu_1 \neq \mu_0$	$T_w = \frac{\bar{Y} - \bar{X} - \mu_0}{S_w} \sqrt{\frac{mn}{m+n}}$ $T_w \mu_0 \sim t_{n+m-2}$	$ T_w > t_{n+m-2}(\alpha/2)$
		$\mu_2 - \mu_1 \leq \mu_0$	$\mu_2 - \mu_1 > \mu_0$		$T_w > t_{n+m-2}(\alpha)$
		$\mu_2 - \mu_1 \geq \mu_0$	$\mu_2 - \mu_1 < \mu_0$		$T_w < -t_{n+m-2}(\alpha)$
	μ_1, μ_2 已知	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F_* = \frac{S_{2*}^2}{S_{1*}^2} \quad F_* \sigma_2^2 = \sigma_1^2 \sim F_{n,m}$ $S_{1*}^2 = \frac{1}{m} \sum (X_i - \mu_1)^2$ $S_{2*}^2 = \frac{1}{n} \sum (Y_i - \mu_2)^2$	$F_* < F_{n,m}(1 - \alpha/2)$ 或 $F_* > F_{n,m}(\alpha/2)$
		$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F_* > F_{n,m}(\alpha)$
		$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F_* < F_{n,m}(1 - \alpha)$
	μ_1, μ_2 未知	$\sigma_2^2 = \sigma_1^2$	$\sigma_2^2 \neq \sigma_1^2$	$F = \frac{S_2^2}{S_1^2} \quad F \sigma_2^2 = \sigma_1^2 \sim F_{n-1, m-1}$ $S_1^2 = \frac{1}{m-1} \sum (X_i - \bar{X})^2$ $S_2^2 = \frac{1}{n-1} \sum (Y_i - \bar{Y})^2$	$F < F_{n-1, m-1}(1 - \alpha/2)$ 或 $F > F_{n-1, m-1}(\alpha/2)$
		$\sigma_2^2 \leq \sigma_1^2$	$\sigma_2^2 > \sigma_1^2$		$F > F_{n-1, m-1}(\alpha)$
		$\sigma_2^2 \geq \sigma_1^2$	$\sigma_2^2 < \sigma_1^2$		$F < F_{n-1, m-1}(1 - \alpha)$

$$\text{其中 } S_w = \sqrt{\frac{(m-1)S_1^2 + (n-1)S_2^2}{m+n-2}}$$

注 2.1. 1. 不难注意到其实拒绝域的区间方向和备择假设是一样的，并且当考虑正态分布或者 *student-t* 分布的统计量时，才会在相等的 H_0 下得到绝对值类型的拒绝域（此时一般用 $\frac{\alpha}{2}$ 对应的数值, 统计量带绝对值）

2. 成对数据往往作差转换为一样本问题

3. 均值未知时 S^2 的分母是 $n-1$ ，均值已知时 S_{μ}^2 的分母是 n ，对应的自由度也是 $n-1$ 和 n

4. 对于两样本检验，如果没有给出具体是关于均值还是方差的假设，需要先检验方差是否相等，再检验均值

2.2 功效函数和两类错误

定义 2.1 (功效函数). 设总体为 $F(x, \theta)$, 其中 $\theta = (\theta_1, \theta_2, \dots, \theta_k) \in \Theta \subseteq \mathbb{R}^k$ 为参数, H_0 是关于参数 θ 的一个原假设, 设 Ψ 是根据样本 $(X_1, X_2, \dots, X_n)$ 对假设所作的一个检验, 则称

$$\beta_{\Psi}(\theta) = P_{\theta}(\text{在检验 } \Psi \text{ 下 } H_0 \text{ 被否定})$$

为检验 Ψ 的功效函数

两类错误定义如表格:

决策	事实	
	H_0 成立	H_1 成立
不拒绝 H_0	正确	第二类错误
拒绝 H_0	第一类错误	正确

$$\alpha_{1\Psi}(\theta) = \begin{cases} \beta_{\Psi}(\theta) & \theta \in H_0 \\ 0 & \theta \in H_1 \end{cases}$$

$$\alpha_{2\Psi}(\theta) = \begin{cases} 0 & \theta \in H_0 \\ 1 - \beta_{\Psi}(\theta) & \theta \in H_1 \end{cases}$$

注 2.2. 1. 特别注意 *power function* 计算的是 H_0 被否定的概率

2. 更加一般的, 我们称第一类错误为弃真错误, 第二类错误为存伪错误 (都是针对 H_0), 所以第一类错误是 H_0 成立但是拒绝, 第二类错误是 H_1 成立但是接受 H_0 (因此集合是 *power function* 对应的集合的补集)

2.3 选择 H_0

设立原假设和备择假设的两条原则:

1. 把已有的经过考验的结论或事实作为原假设 H_0
2. 把你希望得到的结论放在备择假设 H_1 , 希望能通过拒绝原假设得到你的结论

注 2.3. 由于设定的犯第一类错误的概率上限 α 很小, 即在原假设成立的条件下根据样本在检验 Ψ 下拒绝原假设是小概率事件, 所以原假设和备择假设的地位是不平等的。我们是站在保护原假设的立场上, 即没有足够的证据, 我们不会拒绝原假设 H_0

2.4 相关期末题

例 2.1. 设 X 的概率密度函数为 $f(x) = (1 + \theta)x^{\theta}$, $0 < x < 1$ 。现考虑假设检验问题 $H_0: \theta = 5 \leftrightarrow H_1: \theta = 3$ 。该检验的否定域为 $X > 1/2$, 则犯第一类错误和第二类错误的概率分别为多少?

解. 1. 第一类错误是指在 H_0 为真时, 错误地拒绝了 H_0 , 即 $\theta = 5$ 时, $X > \frac{1}{2}$ 的概率。在 H_0 为真时, $f_0(x) = 6x^5$, 因此犯第一类错误的概率为:

$$\alpha = P(X > \frac{1}{2} | \theta = 5) = \int_{\frac{1}{2}}^1 6x^5 dx = 6 \left[\frac{x^6}{6} \right]_{\frac{1}{2}}^1 = 1 - \left(\frac{1}{2} \right)^6 = \frac{63}{64}$$

2. 第二类错误是指在 H_1 为真时, 错误地接受了 H_0 , 即 $\theta = 3$ 时, $X \leq \frac{1}{2}$ 的概率。在 H_1 为真时, $f_1(x) = 4x^3$, 因此犯第二类错误的概率为:

$$\beta = P(X \leq \frac{1}{2} | \theta = 3) = \int_0^{\frac{1}{2}} 4x^3 dx = 4 \left[\frac{x^4}{4} \right]_0^{\frac{1}{2}} = \frac{1}{16}$$

□

例 2.2. 设 X_1, X_2, X_3 是来自总体 $X \sim \begin{pmatrix} 1 & 2 & 3 \\ \theta^2 & 2\theta(1-\theta) & (1-\theta)^2 \end{pmatrix}$ 的一组简单随机样本, 若假设检验 $H_0: \theta = 0.1 \leftrightarrow H_1: \theta = \theta_1$ 的拒绝域为 $\{X_1 = X_2 = X_3 = 1\}$, 其中 $0.5 < \theta_1 < 1$ 是一个给定的常数, 则此检验犯第二类错误的概率为 ____

解. 第二类错误的概率 β 是指在 H_1 为真时, 错误地接受了 H_0 , 即:

$$\beta = P(\text{接受 } H_0 | H_1 \text{ 为真}) = 1 - P(X_1 = X_2 = X_3 = 1 | \theta = \theta_1)$$

由于 X_1, X_2, X_3 独立, 且 $P(X = 1 | \theta = \theta_1) = \theta_1^2$, 所以

$$P(X_1 = X_2 = X_3 = 1 | \theta = \theta_1) = (\theta_1^2)^3 = \theta_1^6$$

故 $\beta = 1 - \theta_1^6$.

□

例 2.3. 在 2021 年日本东京奥运会中, 我国运动员杨倩和杨皓然获得了射击混合双人团体 10 米气步枪金牌。决赛中 15 轮射击结果如下 (单位: 环):

杨倩	10.5	9.7	10.0	10.5	10.3	10.2	10.1	10.6	10.4	9.9	10.8	10.8	10.4	10.4	10.4
杨皓然	10.3	10.4	10.9	10.2	10.5	10.4	10.2	10.8	10.6	10.0	10.5	10.7	10.4	10.1	10.7

设两位运动员的每次射击结果相互独立, 且均服从正态分布。利用上述数据回答 (显著性水平 $\alpha = 0.05$):

1. 两位运动员射击成绩的方差是否可以认为是相等的?
2. 假设“杨皓然平均射击水平高于杨倩”是否显著成立?

解. 设杨倩的样本为 $X_1, \dots, X_{15}$, 杨皓然的样本为 $Y_1, \dots, Y_{15}$ 。

对于杨倩:

$$\bar{X} = \frac{1}{15} \sum_{i=1}^{15} X_i = 10.333, \quad (n_1 - 1)S_1^2 = \sum_{i=1}^{15} (X_i - \bar{X})^2 = 1.353, \quad S_1^2 = \frac{1.353}{14} \approx 0.09664$$

对于杨皓然:

$$\bar{Y} = \frac{1}{15} \sum_{i=1}^{15} Y_i = 10.447, \quad (n_2 - 1)S_2^2 = \sum_{i=1}^{15} (Y_i - \bar{Y})^2 = 0.957, \quad S_2^2 = \frac{0.957}{14} \approx 0.06836$$

1. 方差齐性检验 (F检验)

检验假设: $H_0: \sigma_1^2 = \sigma_2^2$ vs $H_1: \sigma_1^2 \neq \sigma_2^2$ 。

检验统计量 $F = \frac{S_1^2}{S_2^2} \sim F_{n_1-1, n_2-1} = F_{14,14}$ (在 H_0 下)。

计算得 $F = \frac{0.09664}{0.06836} \approx 1.414$

临界值 $F_{14,14}(0.025) = 2.979$, $\frac{1}{F_{14,14}(0.025)} \approx 0.336$

决策规则: 当 $F < 0.336$ 或 $F > 2.979$ 时拒绝 H_0

检验结果: $0.336 < 1.414 < 2.979$, 故接受 H_0 。在显著性水平 $\alpha = 0.05$ 下, 可以认为两位运动员射击成绩的方差相等

2. 均值单侧检验 (t检验)

由于已接受方差相等, 采用合并方差 t 检验

检验假设 (注意题意 “杨皓然高于杨倩” 应检验 $\mu_1 < \mu_2$):

$$H_0: \mu_1 \geq \mu_2 \quad \text{vs} \quad H_1: \mu_1 < \mu_2$$

合并方差:

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} = \frac{1.353 + 0.957}{28} = \frac{2.31}{28} \approx 0.0825, \quad S_w \approx 0.287$$

检验统计量:

$$t = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} = \frac{10.333 - 10.447}{0.287 \sqrt{\frac{2}{15}}} = \frac{-0.114}{0.287 \times 0.365} \approx -1.08$$

临界值 $-t_{n_1+n_2-2}(\alpha) = -t_{28}(0.05) \approx -1.701$

决策规则: 当 $t < -1.701$ 时拒绝 H_0

检验结果: $-1.08 > -1.701$, 故接受 H_0 。在显著性水平 $\alpha = 0.05$ 下, 不能认为杨皓然的比赛成绩显著高于杨倩

□

例 2.4. 为了检验某种体育锻炼对减肥的效果, 随机抽取了 10 名减肥者进行测试。在进行体育锻炼前后这些减肥者的体重 (单位: 千克) 数据列表如下, 问该体育锻炼方法对降低体重是否具有显著性 (设人的体重服从正态分布, 取显著性水平 $\alpha = 0.05$)?

锻炼前体重	70	65	67	58	69	72	74	61	63	67
锻炼后体重	68	60	68	58	67	70	70	60	60	65

解. 成对数据。检验假设 $H_0: \mu_d = 0$ (体重无显著变化) $\leftrightarrow H_1: \mu_d \neq 0$ (体重有显著变化)。

可算得相减之后, 有 $\bar{X} = 2$, $S^2 = 28/9$

计算检验统计量:

$$t = \frac{\sqrt{n}\bar{X}}{S} = \frac{\sqrt{10} \cdot 2}{\sqrt{28/9}} = 3.59$$

查表: $t_9(0.05) = 1.833$, $t = 3.59 > 1.833$, 故拒绝 H_0

可拒绝原假设, 即认为体育锻炼对降低体重具有显著性效果

□

3 点估计

3.1 矩估计

定义 3.1. 设总体 X 的分布函数为 $F(x; \theta_1, \theta_2, \dots, \theta_k)$, 其中 $\theta_1, \theta_2, \dots, \theta_k$ 为待估参数。假设总体的前 k 阶矩存在, 记总体 i 阶原点矩为

$$\mu_i = E(X^i) = \mu_i(\theta_1, \theta_2, \dots, \theta_k), \quad i = 1, 2, \dots, k$$

令样本 i 阶原点矩为

$$A_i = \frac{1}{n} \sum_{j=1}^n X_j^i, \quad i = 1, 2, \dots, k$$

矩估计法的思想是: 用样本矩估计总体矩, 用样本矩的连续函数估计总体矩的连续函数。具体通过解方程组

$$\begin{cases} \mu_1(\theta_1, \dots, \theta_k) = A_1 \\ \mu_2(\theta_1, \dots, \theta_k) = A_2 \\ \vdots \\ \mu_k(\theta_1, \dots, \theta_k) = A_k \end{cases}$$

得到估计量 $\hat{\theta}_i = \hat{\theta}_i(X_1, X_2, \dots, X_n)$, 称为矩估计量

注 3.1 (常考性质总结). 1. **矩估计的不变性**: 设 $\hat{\theta}_1, \dots, \hat{\theta}_k$ 是 $\theta_1, \dots, \theta_k$ 的矩估计量, 若 $h(\cdot)$ 为连续函数, 则 $h(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 是 $h(\theta_1, \dots, \theta_k)$ 的矩估计量

2. **不唯一性**: 参数可能表示为不同阶矩的函数, 导致矩估计不唯一。通常选用最低阶矩求解

3. **相合性**: 样本矩是总体矩的强相合估计, 故矩估计量具有强相合性

4. **有偏性**: 矩估计不一定是无偏估计 (如均匀分布 $U(0, \theta)$ 的矩估计 $\hat{\theta} = 2\bar{X}$ 是有偏的), 但通常是渐近无偏的

3.2 最大似然估计

定义 3.2. 设总体 X 的概率函数 (离散型为分布律, 连续型为密度函数) 为 $f(x; \theta)$, 其中 $\theta \in \Theta$ 为待估参数。对于样本 $(X_1, X_2, \dots, X_n)$, 其**似然函数**定义为

$$L(\theta) = L(\theta; X_1, \dots, X_n) = \prod_{i=1}^n f(X_i; \theta)$$

最大似然估计 (MLE) 的思想是选择使样本出现概率最大的参数值作为估计:

$$\hat{\theta}_{MLE} = \arg \max_{\theta \in \Theta} L(\theta)$$

一般来说, 我们有两种方法获取最大似然估计

1. **用微积分中求极值的方法**: 若似然函数 $L(\theta, \mathbf{x})$ 连续可微, 可通过求导找极值点。由于 $\ln L$ 与 L 同极值点且更易处理, 通常对对数似然函数 $l(\theta) = \ln L$ 求极值

求解步骤:

(1) 建立似然方程组 $\frac{\partial l(\theta)}{\partial \theta_i} = 0, i = 1, 2, \dots, k$

(2) 求解得到 $\hat{\theta}^*$

(3) 验证: 若 $\hat{\theta}^*$ 是参数空间 Θ 的内点且方程组解唯一, 则 $\hat{\theta}^*$ 为最大似然估计

2. 从定义出发: 当似然函数 $L(\theta, \mathbf{x})$ 对参数 θ 不可微, 甚至不连续时, 似然方程一般没有意义, 必须直接从定义出发去求参数 θ 的极大似然估计

注 3.2 (常考性质总结). 1. 不变性: 设 $\hat{\theta}$ 是 θ 的 MLE, 若 $g(\cdot)$ 是连续可逆函数, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的 MLE

2. 唯一性: 在通常情况下, MLE 具有唯一性 (严格凹对数似然函数保证)

3. 相合性: 在一定的正则条件下, MLE 是强相合估计

4. 有偏性: MLE 在小样本情况下可能有偏

3.3 无偏估计

定义 3.3 (偏差与无偏性). 设 $\hat{g}(X_1, X_2, \dots, X_n)$ 是 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的一个估计量, 称

$$E_{\theta}(\hat{g}(X_1, X_2, \dots, X_n)) - g(\theta_1, \theta_2, \dots, \theta_k)$$

为估计量 $\hat{g}$ 的偏差. 若对任一可能的 $(\theta_1, \dots, \theta_k) \in \Theta$, 都有

$$E_{\theta_1, \dots, \theta_k}(\hat{g}(X_1, X_2, \dots, X_n)) = g(\theta_1, \theta_2, \dots, \theta_k)$$

则称 $\hat{g}$ 是 $g(\theta_1, \theta_2, \dots, \theta_k)$ 的一个无偏估计量

3.4 相关期末题

例 3.1. (23秋季第三题)下述表述错误的是 ()

(A) 矩估计量一般不唯一

(B) 无偏估计总是优于有偏估计

(C) 相合性是一个估计量应具有的性质

(D) 最大似然估计可以不存在

解答:

(A) 矩估计量可能不唯一, 可以使用不同阶的矩建立方程, 或者方程组的解可能不唯一

(B) 无偏估计不一定优于有偏估计, 评价估计量的优劣通常采用均方误差等准则, 有时有偏估计的均方误差更小, 故 B 错误

(C) 相合性 (一致性) 是估计量的一个良好性质, 但并非所有估计量都具有相合性

(D)最大似然估计可能不存在, 例如当似然函数在参数空间内无最大值点

例 3.2. (25秋季第八题) 设统计量 $\hat{\theta}$ 为总体参数 θ 的一个点估计, 下列说法一般不成立的是 (C)

(A) 若 $\hat{\theta}$ 为 θ 的矩估计, 则 $\hat{\theta}^2$ 为 θ^2 的矩估计

(B) 若 $\hat{\theta}$ 为 θ 的最大似然估计, 则 $\hat{\theta}^2$ 为 θ^2 的最大似然估计

(C) 若 $\hat{\theta}$ 为 θ 的无偏估计, 则 $\hat{\theta}^2$ 为 θ^2 的无偏估计

(D) 若 $\hat{\theta}$ 为 θ 的相合估计, 则 $\hat{\theta}^2$ 为 θ^2 的相合估计

解答: C 错误: 无偏估计对非线性映射不保持不变性, AB 自然成立, D 这边是依概率收敛的性质 (后面会总结统计量的几个性质)

例 3.3. 设总体 X 的密度函数为

$$f(x) = \frac{2x}{a^2}, \quad 0 \leq x \leq a,$$

其中 $a > 0$ 为未知参数, 而 $X_1, X_2, \dots, X_n$ 是来自该总体的一组简单随机样本。

1. 求 a 的矩估计量 $\hat{a}_1$ 和极大似然估计量 $\hat{a}_2$

2. 求 $p = P(0 < X < \sqrt{a})$ 的极大似然估计量 $\hat{p}$

3. 问 $\hat{a}_1$ 和 $\hat{a}_2$ 是否为无偏估计? 若是, 请证明你的结论; 若不是, 请修正之

解. 1. (a) 矩估计: 首先计算总体期望

$$E(X) = \int_0^a x \cdot f(x) dx = \int_0^a x \cdot \frac{2x}{a^2} dx = \frac{2}{a^2} \int_0^a x^2 dx = \frac{2}{a^2} \cdot \frac{a^3}{3} = \frac{2a}{3}$$

令样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 等于总体期望, 即 $\bar{X} = \frac{2a}{3}$, 解得矩估计量 $\hat{a}_1 = \frac{3}{2} \bar{X}$

(b) 极大似然估计: 样本的似然函数为

$$L(a, \mathbf{x}) = \prod_{i=1}^n f(x_i) = \prod_{i=1}^n \frac{2x_i}{a^2} \cdot \mathbf{1}_{\{0 \leq x_i \leq a\}} = \left(\frac{2}{a^2}\right)^n \left(\prod_{i=1}^n x_i\right) \cdot \mathbf{1}_{\{x_{(n)} \leq a\}}$$

其中 $x_{(n)} = \max\{x_1, \dots, x_n\}$ 。记 $X_{(n)}$ 为相应的次序统计量。因此, 似然函数在 $a = X_{(n)}$ 处取得最大值, 极大似然估计量为 $\hat{a}_2 = X_{(n)}$

2. 首先计算概率 p :

$$p = P(0 < X < \sqrt{a}) = \int_0^{\sqrt{a}} \frac{2x}{a^2} dx = \frac{1}{a^2} [x^2]_0^{\sqrt{a}} = \frac{a}{a^2} = \frac{1}{a}$$

由极大似然估计的不变性 (MLE 的不变性定理), 若 $\hat{a}_2$ 是 a 的 MLE, 则 $g(\hat{a}_2)$ 是 $g(a)$ 的 MLE (其中 g 为连续函数)。取 $g(a) = 1/a$, 得到 $\hat{p} = \frac{1}{\hat{a}_2} = \frac{1}{X_{(n)}}$

3. (a) 矩估计 $\hat{a}_1$ 的无偏性:

$$E(\hat{a}_1) = E\left(\frac{3}{2} \bar{X}\right) = \frac{3}{2} E(\bar{X}) = \frac{3}{2} E(X) = \frac{3}{2} \cdot \frac{2a}{3} = a$$

因此 $\hat{a}_1$ 是 a 的无偏估计

(b) 极大似然估计 $\hat{a}_2$ 的无偏性: 首先求 $X_{(n)}$ 的密度函数。总体 X 的分布函数为

$$F(x) = \int_0^x \frac{2t}{a^2} dt = \frac{x^2}{a^2}, \quad 0 \leq x \leq a$$

则 $X_{(n)}$ 的密度函数为

$$h(x) = n[F(x)]^{n-1}f(x) = n\left(\frac{x^2}{a^2}\right)^{n-1} \cdot \frac{2x}{a^2} = \frac{2n}{a^{2n}}x^{2n-1}, \quad 0 < x < a$$

计算其期望:

$$E(\hat{a}_2) = E(X_{(n)}) = \int_0^a x \cdot h(x) dx = \int_0^a x \cdot \frac{2n}{a^{2n}} x^{2n-1} dx = \frac{2n}{a^{2n}} \int_0^a x^{2n} dx = \frac{2n}{a^{2n}} \cdot \frac{a^{2n+1}}{2n+1} = \frac{2n}{2n+1}a$$

故 $\hat{a}_2$ 是有偏估计, 偏差为 $-\frac{a}{2n+1}$

修正: 为使估计无偏, 令修正系数 c 满足 $E(cX_{(n)}) = a$, 即

$$c \cdot \frac{2n}{2n+1}a = a \Rightarrow c = \frac{2n+1}{2n}$$

因此修正后的无偏估计为 $\hat{a}_2^* = \frac{2n+1}{2n}X_{(n)}$

□

例 3.4. 已知总体 X 的概率密度函数为 $f(x) = (\theta + 1)x^\theta$, $0 < x < 1$, 其中 $\theta > -1$ 为一未知参数。设 $X_1, X_2, \dots, X_n$ 是来自该总体的一组简单随机样本。

1. 求 θ 的矩估计量 $\hat{\theta}$;
2. 求 $g(\theta) = \frac{1}{\theta+1}$ 的极大似然估计量 $\hat{g}$
3. 问 $\hat{g}$ 是否为 $g(\theta)$ 的一个无偏估计? 证明你的结论
4. 求常数 b , 使得对任意实数 x , 都有 $\lim_{n \rightarrow \infty} P(\sqrt{n}(\hat{g} - g(\theta))/b \leq x) = \Phi(x)$

解. 1. 首先计算总体期望:

$$E(X) = \int_0^1 x \cdot (\theta + 1)x^\theta dx = (\theta + 1) \int_0^1 x^{\theta+1} dx = (\theta + 1) \cdot \frac{1}{\theta + 2} = \frac{\theta + 1}{\theta + 2}.$$

令样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 等于总体期望, 建立矩方程:

$$\frac{\theta + 1}{\theta + 2} = \bar{X}$$

解此方程求 θ :

$$\theta + 1 = \bar{X}(\theta + 2) \Rightarrow \theta + 1 = \bar{X}\theta + 2\bar{X} \Rightarrow \theta - \bar{X}\theta = 2\bar{X} - 1 \Rightarrow \theta(1 - \bar{X}) = 2\bar{X} - 1$$

$$\hat{\theta} = \frac{2\bar{X} - 1}{1 - \bar{X}}$$

2. 似然函数:

$$L(\theta) = \prod_{i=1}^n f(X_i) = \prod_{i=1}^n (\theta+1)X_i^\theta = (\theta+1)^n \left(\prod_{i=1}^n X_i \right)^\theta$$

对数似然函数:

$$l(\theta) = \ln L(\theta) = n \ln(\theta+1) + \theta \sum_{i=1}^n \ln X_i$$

求导:

$$\frac{dl(\theta)}{d\theta} = \frac{n}{\theta+1} + \sum_{i=1}^n \ln X_i$$

令导数为零:

$$\frac{n}{\theta+1} + \sum_{i=1}^n \ln X_i = 0 \Rightarrow \frac{1}{\theta+1} = -\frac{1}{n} \sum_{i=1}^n \ln X_i.$$

因此 $g(\theta) = \frac{1}{\theta+1}$ 的极大似然估计量为

$$\hat{g} = -\frac{1}{n} \sum_{i=1}^n \ln X_i$$

3. 令 $Y_i = -\ln X_i$, $i = 1, 2, \dots, n$, 下证 $\{Y_i\}$ 服从参数为 $\theta+1$ 的指数分布

由变量变换公式, $X_i = e^{-Y_i}$, 雅可比行列式为 $\left| \frac{dx}{dy} \right| = e^{-y}$. 则 Y_i 的密度函数为

$$f_Y(y) = f_X(e^{-y}) \cdot \left| \frac{dx}{dy} \right| = (\theta+1)(e^{-y})^\theta \cdot e^{-y} = (\theta+1)e^{-(\theta+1)y}, \quad y > 0$$

这正是参数为 $\theta+1$ 的指数分布 $Exp(\theta+1)$

因此

$$E(Y_i) = \frac{1}{\theta+1}, \quad \text{Var}(Y_i) = \frac{1}{(\theta+1)^2}$$

由于 $\hat{g} = \frac{1}{n} \sum_{i=1}^n Y_i$, 故

$$E(\hat{g}) = E\left(\frac{1}{n} \sum_{i=1}^n Y_i\right) = \frac{1}{n} \sum_{i=1}^n E(Y_i) = \frac{1}{\theta+1} = g(\theta)$$

所以 $\hat{g}$ 是 $g(\theta)$ 的无偏估计。

4. 由3知 $\hat{g} = \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$, 其中 $\{Y_i\}$ 独立同分布, $E(Y_i) = \frac{1}{\theta+1}$, $\text{Var}(Y_i) = \frac{1}{(\theta+1)^2}$. 根据经典中心极限定理 (CLT), 当 $n \rightarrow \infty$ 时

$$\sqrt{n}(\bar{Y} - E(Y_1)) \xrightarrow{d} N(0, \text{Var}(Y_1))$$

即

$$\sqrt{n}(\hat{g} - g(\theta)) \xrightarrow{d} N\left(0, \frac{1}{(\theta+1)^2}\right).$$

为使 $\frac{\sqrt{n}(\hat{g}-g(\theta))}{b} \xrightarrow{d} N(0,1)$, 需取

$$b = \sqrt{\text{Var}(Y_1)} = \frac{1}{\theta+1}$$

因此所求常数为 $b = \frac{1}{\theta+1}$

□

例 3.5. 设一系列随机变量 $Y_1, Y_2, \dots, Y_n$ 满足

$$Y_i = \beta x_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

其中 $x_1, x_2, \dots, x_n$ 为给定非负常数且不全相等, $\varepsilon_1, \dots, \varepsilon_n$ 相互独立且均服从正态分布 $N(0, \sigma^2)$, 而 β 和 σ^2 为两个未知参数

1. 根据 $Y_1, Y_2, \dots, Y_n$ 的分布, 请写出似然函数 $L(\beta, \sigma^2)$ 。
2. 试求 β 的极大似然估计量 $\hat{\beta}$, 并证明 $\hat{\beta}$ 为 β 的一个无偏估计
3. 证明 $\hat{\beta}^* = \frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n x_i}$ 也为 β 的一个无偏估计, 并比较 $\hat{\beta}$ 和 $\hat{\beta}^*$ 哪个更有效

解. 1. 由模型设定可知 $Y_i \sim N(\beta x_i, \sigma^2)$ 且相互独立。正态分布密度函数为

$$f(y_i; \beta, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y_i - \beta x_i)^2}{2\sigma^2} \right\}$$

因此联合密度函数 (即似然函数) 为

$$L(\beta, \sigma^2) = \prod_{i=1}^n f(y_i; \beta, \sigma^2) = \frac{1}{(\sqrt{2\pi}\sigma)^n} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2 \right\}$$

2. 对数似然函数为

$$l(\beta, \sigma^2) = \ln L(\beta, \sigma^2) = -\frac{n}{2} \ln(2\pi) - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)^2$$

对 β 求偏导 (σ^2 视为常数):

$$\frac{\partial l}{\partial \beta} = -\frac{1}{2\sigma^2} \sum_{i=1}^n 2(y_i - \beta x_i)(-x_i) = \frac{1}{\sigma^2} \sum_{i=1}^n (y_i - \beta x_i)x_i$$

令 $\frac{\partial l}{\partial \beta} = 0$ 得

$$\sum_{i=1}^n (y_i - \beta x_i)x_i = 0 \Rightarrow \sum_{i=1}^n x_i y_i - \beta \sum_{i=1}^n x_i^2 = 0$$

解得 β 的极大似然估计量为

$$\hat{\beta} = \frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2}$$

由于 $\hat{\beta}$ 是独立正态随机变量 Y_i 的线性组合, 故 $\hat{\beta}$ 也服从正态分布。计算其期望:

$$E(\hat{\beta}) = E \left(\frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2} \right) = \frac{1}{\sum_{i=1}^n x_i^2} \sum_{i=1}^n x_i E(Y_i) = \frac{1}{\sum_{i=1}^n x_i^2} \sum_{i=1}^n x_i (\beta x_i) = \beta \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n x_i^2} = \beta$$

计算方差 (利用 $\{Y_i\}$ 独立性):

$$\text{Var}(\hat{\beta}) = \text{Var} \left(\frac{\sum_{i=1}^n x_i Y_i}{\sum_{i=1}^n x_i^2} \right) = \frac{1}{(\sum_{i=1}^n x_i^2)^2} \sum_{i=1}^n x_i^2 \text{Var}(Y_i) = \frac{1}{(\sum_{i=1}^n x_i^2)^2} \sum_{i=1}^n x_i^2 \sigma^2 = \frac{\sigma^2}{\sum_{i=1}^n x_i^2}$$

因此 $\hat{\beta}$ 是 β 的无偏估计

3. 计算 $\hat{\beta}^*$ 的期望:

$$E(\hat{\beta}^*) = E\left(\frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n x_i}\right) = \frac{1}{\sum_{i=1}^n x_i} \sum_{i=1}^n E(Y_i) = \frac{1}{\sum_{i=1}^n x_i} \sum_{i=1}^n \beta x_i = \beta \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n x_i} = \beta$$

计算方差:

$$\text{Var}(\hat{\beta}^*) = \text{Var}\left(\frac{\sum_{i=1}^n Y_i}{\sum_{i=1}^n x_i}\right) = \frac{1}{(\sum_{i=1}^n x_i)^2} \sum_{i=1}^n \text{Var}(Y_i) = \frac{1}{(\sum_{i=1}^n x_i)^2} \sum_{i=1}^n \sigma^2 = \frac{n\sigma^2}{(\sum_{i=1}^n x_i)^2}$$

因此 $\hat{\beta}^*$ 也是 β 的无偏估计

有效性比较: 比较两个估计量的方差。根据 Cauchy-Schwarz 不等式:

$$\left(\sum_{i=1}^n x_i\right)^2 = \left(\sum_{i=1}^n x_i \cdot 1\right)^2 \leq \left(\sum_{i=1}^n x_i^2\right) \left(\sum_{i=1}^n 1^2\right) = n \sum_{i=1}^n x_i^2$$

由于 x_i 不全相等且非负, 不等式严格成立:

$$\left(\sum_{i=1}^n x_i\right)^2 < n \sum_{i=1}^n x_i^2$$

因此

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum_{i=1}^n x_i^2} < \frac{n\sigma^2}{(\sum_{i=1}^n x_i)^2} = \text{Var}(\hat{\beta}^*)$$

故 $\hat{\beta}$ 比 $\hat{\beta}^*$ 更有效

□

4 统计量的性质

4.1 无偏性 (Unbiasedness)

定义 4.1. 设总体分布含有未知参数 θ , $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 是 θ 的一个估计量。如果对任意 $\theta \in \Theta$ 都有

$$E_{\theta}(\hat{\theta}) = \theta$$

则称 $\hat{\theta}$ 是 θ 的**无偏估计**。若 $E(\hat{\theta}) \neq \theta$, 则称为有偏估计, 偏差为 $b(\theta) = E(\hat{\theta}) - \theta$

直观含义: 无偏性意味着估计量的取值在参数真值附近波动, 平均而言没有系统误差。重复抽样下, 估计值的均值会稳定在真值上

例 4.1. 设 $X_1, \dots, X_n$ 来自总体 $N(\mu, \sigma^2)$, 则

$$E(\bar{X}) = \mu, \quad E(S^2) = \sigma^2,$$

其中 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$ 。因此 $\bar{X}$ 是 μ 的无偏估计, S^2 是 σ^2 的无偏估计

注意: 无偏性不具有变换不变性: 若 $\hat{\theta}$ 是 θ 的无偏估计, 一般 $g(\hat{\theta})$ 不是 $g(\theta)$ 的无偏估计 (除了线性函数)。

4.2 相合性 (Consistency)

定义 4.2. 设 $\hat{\theta}_n$ 是基于样本量 n 的估计量。如果对任意 $\varepsilon > 0$ 和任意 $\theta \in \Theta$ 有

$$\lim_{n \rightarrow \infty} P_{\theta}(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

则称 $\hat{\theta}_n$ 是 θ 的相合估计 (或一致估计), 记作 $\hat{\theta}_n \xrightarrow{P} \theta$

直观含义: 当样本量越来越大时, 估计量依概率收敛于参数真值, 即 “大样本下估计几乎一定准确”。相合性是一个大样本性质, 是估计量的基本要求。

常见判别方法:

- 由大数定律, 样本均值 $\bar{X}$ 是 μ 的相合估计
- 矩估计在适当条件下是相合的
- 最大似然估计在正则条件下是相合的

例 4.2. 样本方差 $S_n^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ 是 σ^2 的相合估计 (虽然它是有偏的, 但偏差趋于 0)

总结

下表概括了这两种性质的主要特点:

性质	关注点	样本量要求	是否传递变换	常用工具/定理
无偏性	均值偏差	任意	否 (非线性)	期望的线性性
相合性	概率收敛	大样本	是 (连续函数)	大数定律, Chebyshev不等式

5 拟合优度检验

5.1 理论分布完全已知且只取有限个值

对于检验问题:

$$H_0: P(X = a_i) = p_i, i = 1, 2, \dots, k \quad \leftrightarrow \quad H_1: \exists j, P(X = a_j) \neq p_j$$

列表如下:

类别	a_1	a_2	$\dots$	a_i	$\dots$	a_k
理论值(E)	np_1	np_2	$\dots$	np_i	$\dots$	np_k
观测值(O)	n_1	n_2	$\dots$	n_i	$\dots$	n_k
$E - O$	$np_1 - n_1$	$np_2 - n_2$	$\dots$	$np_i - n_i$	$\dots$	$np_k - n_k$

皮尔逊统计量即是

$$Z = \sum \frac{(O - E)^2}{E} = \sum_{i=1}^k \frac{(np_i - n_i)^2}{np_i} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n$$

定理 5.1 (皮尔逊 χ^2 检验). 如果原假设 H_0 成立, 那么当样本量 $n \rightarrow \infty$ 时, Z 的分布趋于自由度为 $k - 1$ 的 χ^2 分布, 即 χ_{k-1}^2

5.2 理论分布类型已知但含有有限个未知参数

首先考虑总体 X 取有限个值 $\{a_1, a_2, \dots, a_k\}$ 。此时分布中含有 r 个未知的参数 $\theta_1, \theta_2, \dots, \theta_r$ ，即原假设为

$$H'_0: P(X = a_i) = p_i(\theta_1, \theta_2, \dots, \theta_r), \quad i = 1, 2, \dots, k$$

记样本为 $(X_1, X_2, \dots, X_n)$ ，在原假设 H'_0 下，参数 $\theta_1, \dots, \theta_r$ 的最大似然估计为 $\hat{\theta}_1, \dots, \hat{\theta}_r$ ，从而 p_i 的最大似然估计为 $\hat{p}_i = p_i(\hat{\theta}_1, \dots, \hat{\theta}_r)$ ， $i = 1, 2, \dots, k$ 。用 n_i 表示样本中取 a_i 的个数，则构建统计量

$$Z = \sum_{i=1}^k \frac{(n_i - n\hat{p}_i)^2}{n\hat{p}_i}$$

有如下的结论：

定理 5.2. 在一定的条件下，若原假设 H'_0 成立，则当 $n \rightarrow \infty$ 时， Z 的分布趋于自由度为 $k - r - 1$ 的 χ^2 分布，即 χ^2_{k-r-1}

然后考虑总体 X 取无穷多个值，但其分布中仅含有有限个未知参数。此时原假设可以表示为

$$H''_0: X \sim F_\theta(x), \quad x \in \mathbb{R}$$

其中 $\theta = (\theta_1, \theta_2, \dots, \theta_r)$ 为未知参数，它们在一定区域内变化。我们可以将总体的取值切为 k 段，记切分出的区间为

$$(x_0, x_1], (x_1, x_2], (x_2, x_3], \dots, (x_{k-2}, x_{k-1}], (x_{k-1}, x_k)$$

其中 $x_0 = -\infty$ ， $x_k = \infty$ ，则定义离散型随机变量

$$Y = a_i, \quad x_{i-1} < X \leq x_i, \quad i = 1, 2, \dots, k$$

则当原假设 H''_0 成立时，随机变量 Y 的分布为

$$P(Y = a_i) = p_i(\theta_1, \theta_2, \dots, \theta_r), \quad i = 1, 2, \dots, k$$

其中 $p_i(\theta_1, \dots, \theta_r) = F_\theta(x_i) - F_\theta(x_{i-1})$ 。所以，如果拒绝了假设的理论分布，那么有理由拒绝原假设 H''_0 。也就是说，我们将检验假设 H''_0 的问题转换为检验理论分布对应的假设 H'_0 的问题

5.3 列联表检验

列联表的一般形式：

B	A			总计
	1	2	a	
1	n_{11}	n_{12}	n_{1a}	$n_{1\cdot}$
2	n_{21}	n_{22}	n_{2a}	$n_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
b	n_{b1}	n_{b2}	n_{ba}	$n_{b\cdot}$
总计	$n_{\cdot 1}$	$n_{\cdot 2}$	$n_{\cdot a}$	n

要检验 $H_0: A$ 与 B 独立。检验统计量为

$$Z = \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n_{i \cdot} n_{\cdot j} / n)^2}{n_{i \cdot} n_{\cdot j} / n} = \sum_{i=1}^a \sum_{j=1}^b \frac{(nn_{ij} - n_{i \cdot} n_{\cdot j})^2}{nn_{i \cdot} n_{\cdot j}},$$

其中 $n_{i \cdot} = \sum_{j=1}^b n_{ij}$, $n_{\cdot j} = \sum_{i=1}^a n_{ij}$ 。

当 $n \rightarrow \infty$ 时, Z 的渐近分布是自由度为 $(a-1)(b-1)$ 的 χ^2 分布, 即 $\chi^2_{(a-1)(b-1)}$ 。

注 5.1 (齐一性检验)。公式与表格都和列联表检验一样, 但是解决的检验问题不一样

重要区别: 在齐一性问题中, 第 i 个总体中抽取的样本 $n_{i \cdot}$ 是事先给定的, 它没有随机性。而在独立性问题中 $n_{i \cdot}$ 并未事先指定, 它是随机变量。下面有两个典型例子

例 5.1. 上海证券综合指数简称“上证指数”, 反映了上海证券交易所上市股票价格的变动情况。自上证指数诞生的二十七年(1991年1月至2017年12月)以来, 所有月份上涨或下跌的情况如下:

月份	一	二	三	四	五	六	七	八	九	十	十一	十二
上涨月数	14	21	16	15	14	14	13	15	11	13	18	13
下跌月数	13	6	11	12	13	13	14	12	16	14	9	14

结合你所学的知识, 我们能否认为上证指数的涨跌与月份有关?

解. 齐一性检验。两行的和分别为177和147, 每列之和均为27。由此可算得 χ^2 统计量的值为 $11.394 < \chi^2_{11}(0.05) = 19.675$, 故可认为“无充分证据表明上证指数的涨跌与月份有关”或“上证指数的涨跌与月份无关”。□

例 5.2. 为研究色盲是否与性别有关, 调查1000人, 结果见下表

	男	女	合计
正常	442	514	956
色盲	38	6	44
合计	480	520	1000

问色盲是否与性别有关 ($\alpha = 0.01$)?

解. 列联表检验。检验问题为 H_0 : 色盲和性别独立。此例中 $n = 1000$, $r = s = 2$, 查表 $\chi^2_{(r-1)(s-1)}(\alpha) = \chi^2_1(0.01) = 6.64$ 。可计算检验统计量

$$Z = \frac{1000(442 \times 6 - 514 \times 38)^2}{956 \times 44 \times 480 \times 520} = 27.14 > \chi^2_1(0.01) = 6.64,$$

拒绝原假设, 这表明色盲和性别有非常密切的关系。□

5.4 相关期末题

例 5.3. 中国科学技术大学2019级本科新生入学考试中, 某学院两个班级的英语科目各档成绩(从低到高)人数如下表所示:

档次	I	II	III	IV	V	VI	合计
一班	8	27	10	6	8	6	65
二班	15	25	8	7	6	4	65

我们能否认为这两个班级的英语水平大致相当? 显著性水平设为 $\alpha = 0.05$

解. 齐一性检验。原假设为两个班级的英语水平相当, 其检验统计量为

$$\chi^2 = \sum_{i=1}^2 \sum_{j=1}^6 \frac{(nn_{ij} - n_{i.}n_{.j})^2}{nn_{i.}n_{.j}}.$$

代入数据计算可知, $\chi^2 = 3.1922 < \chi_5^2(0.05) = 11.071$, 故在显著性水平 $\alpha = 0.05$ 下我们不能拒绝原假设, 即可认为两个班级的英语水平相当 $\square$

例 5.4. 某种鸟在起飞前, 双足齐跳的次数 X 服从参数为 p 的几何分布, 即其分布律为 $P(X = k) = p(1-p)^{k-1}$, $k = 1, 2, \dots$ 。某人观测 130 次后, 获得一组样本如下:

k	1	2	3	4	5	6	7	8	9	10	11	12	≥ 13
频数	48	31	20	9	6	5	4	2	1	1	2	1	0

1. 求 p 的最大似然估计值 (精确到小数点后三位);
2. 在拟合优度检验中频数一般不能小于 5, 故需将上述所有 $k \geq 7$ 情形下的频数进行合并, 此时请检验假设 “ X 服从几何分布” 是否成立 (显著性水平 $\alpha = 0.05$)

解. 1. 首先计算样本均值:

$$\sum k \cdot n_k = 1 \times 48 + 2 \times 31 + 3 \times 20 + 4 \times 9 + 5 \times 6 + 6 \times 5 + 7 \times 4 + 8 \times 2 + 9 \times 1 + 10 \times 1 + 11 \times 2 + 12 \times 1 = 363,$$

故 $\bar{X} = 363/130 \approx 2.7923$ 。对几何分布 $E[X] = 1/p$, 由矩估计或极大似然估计可得

$$\hat{p} = \frac{1}{\bar{X}} = \frac{130}{363} \approx 0.358.$$

2. 将 $k \geq 7$ 合并后得到 7 组数据。在 H_0 (服从几何分布) 下, 期望频数 $E_i = n \cdot P(X = k)$:

k	1	2	3	4	5	6	≥ 7
观测频数 O_i	48	31	20	9	6	5	11
概率 $P(X = k)$	p	$p(1-p)$	$p(1-p)^2$	$p(1-p)^3$	$p(1-p)^4$	$p(1-p)^5$	$(1-p)^6$
期望频数 E_i	46.540	29.802	19.081	12.210	7.815	5.001	9.551

检验统计量 (自由度 = $7 - 1 - 1 = 5$):

$$\chi^2 = \sum_{i=1}^7 \frac{(O_i - E_i)^2}{E_i} \approx 1.868 < \chi_5^2(0.05) = 11.071,$$

故接受原假设, 认为 X 服从几何分布 $\square$

例 5.5. 英国女作家 Jane Austen (1775-1817) 的作品有 *Sense and Sensibility*, *Pride and Prejudice* 和 *Emma* 等, 她哥哥在她去世后主持了遗作 *Persuasion* 和 *Northanger Abbey* 两部作品出版。下面表格收集了 *Sense and Sensibility*, *Emma* 和 *Persuasion* 三部作品前两章中常用代表词的出现频数, 根据你所学统计知识, 我们能否认为这三部作品在选择这些常用词的习惯没有差异? (检验水平 $\alpha = 0.05$)

单词	<i>Sense and Sensibility</i>	<i>Emma</i>	<i>Persuasion</i>
<i>a</i>	147	186	184
<i>an</i>	25	26	40
<i>this</i>	32	39	30
<i>that</i>	94	105	59

解. 列联表检验。原假设 H_0 : 这三部作品在选择这些常用词的习惯没有差异。检验统计量为

$$\chi^2 = \sum_{i=1}^4 \sum_{j=1}^3 \frac{(n_{ij} - n_{i \cdot} n_{\cdot j} / n)^2}{n_{i \cdot} n_{\cdot j} / n}.$$

在原假设成立条件下, 该统计量的极限分布是自由度为 $(4-1) \times (3-1) = 6$ 的卡方分布。代入数据计算可得

$$\chi^2 = 19.722 > \chi_{0.05}^2(6) = 12.592,$$

故在 $\alpha = 0.05$ 下, 我们可以拒绝原假设, 即认为这三部作品在选择常用词的习惯上有显著差异 □